

ENSAE 2A
Séries temporelles linéaires
TD n°4

Pour toute remarque, contacter jerome.trinh@ensae.fr

L'objectif de cette séance est de mettre en pratique les méthodes habituelles de traitement des séries temporelles univariées. Il s'agit en particulier de mettre en œuvre l'identification, l'estimation et la sélection d'un modèle pour une série brute donnée.


Remarque : Pour des raisons d'encodage texte, copier-coller les lignes de code peut ne pas donner le résultat voulu. Il faut bien vérifier ce qu'il en sort.

Q1. Ouvrir R et importer la série "Donnees1.csv". On considèrera dans la suite xm la série privée de ses 4 dernières observations.

```
datafile <- "Donnees1.csv"
data <- read.csv(datafile, sep=";")
Nous utiliserons les packages "zoo" qui formalise les séries temporelles de manières pratiques, et "tseries" pour diverses fonctions sur les séries temporelles.
require(zoo)
require(tseries)
On définit  $xm.source$  la série initiale au format "zoo",  $T$  sa longueur et  $xm$  la série privée de ses 4 dernières observations
xm.source <- zoo(data[[1]]) #convertit le 1er élément de data en "zoo"
T <- length(xm.source)
xm <- xm.source[1:(T-4)] #supprime les 4 dernières valeurs
```


Q2. Représenter graphiquement la série xm . Qu'observe-t-on ? Comment peut-on résoudre le problème de saisonnalité de xm ? On note dans la suite $desaison$ la série obtenue par désaisonnalisation de xm , et on supposera que la $desaison$ suit un $ARIMA(p, d, q)$.

```
plot(xm, xaxt="n") #représente xm sans l'axe des abscisses
axis(side=1, at=seq(0, 196, 12)) #affiche l'axe des abscisses par 12 de 0 à 196
```





On suspecte une saisonnalité de périodicité 12, ce que l'on peut confirmer en représentant les fonctions d'auto-corrélation totale de la série.

```
acf(xm) #trace l'autocorrélogramme total
```



On observe effectivement une forte autocorrélation d'ordre 12. On peut tenter de supprimer cette saisonnalité en corrigeant la série par son 12ème retard.



```
desaison <- xm-lag(xm,-12) #retire le 12ème retard
par(mfrow=c(1,2)) #dispose les graphiques en 1 colonne et 2 lignes
plot(desaison)
acf(desaison)
```



La saisonnalité semble avoir été corrigée.

Q3. Etudier les auto-corrélogrammes de la série *desaison*. A priori, est-elle intégrée ?

```
acf(desaison) #trace les fonctions d'autocorrélation totale
pacf(desaison) #trace les fonctions d'autocorrélation partielle
```



L'autocorrélation d'ordre 1 (totale ou partielle, c'est la même chose) est d'environ -0.3, soit petite et loin d'être égales à 1. La série semble donc stationnaire.

Q4. Effectuer le **test de racine unitaire** vous semblant le plus adapté à la série *desaison*. Ce test confirme-t-il les conclusions précédentes ?

La représentation de *desaison* à la question 2 semble nous indiquer que la série ne présente pas de tendance. Nous pouvons donc effectuer par exemple comme test de racine unitaire :

- un test de Dickey-Fuller augmenté (ADF) dans le cas avec constante non nulle et sans tendance
- un test de Phillips-Perron intégrant une constante dans l'équation de régression

Pour ce TD, nous regarderons le test de Phillips-Perron.

```
pp.test(desaison) #pp test sur la série (cas général : avec constante et tendance)
```

Phillips-Perron Unit Root Test

```
data: desaison
```

```
Dickey-Fuller Z(alpha) = -268.96, Truncation lag parameter = 4, p-value = 0.01
```

```
alternative hypothesis: stationary
```


L'hypothèse nulle de racine unitaire est rejetée à un seuil de 95% ($p\text{-value}=0.01; 0.05$), on dira que la série est stationnaire.

Q5. Proposer les ordres maximums p^* , d^* , q^* vraisemblables pour la série *desaison*. Vérifier que le modèle $\text{ARIMA}(p^*, d^*, q^*)$ correspondant est valide.

Soit y la série centrée. On regarde ensuite les autocorrélogrammes total et partiel de y , jusqu'à un horizon raisonnable (deux périodicités = 24).

```
y <- desaison - mean(desaison) #centre la série
```

```
acf(y,24); pacf(y,24) # le point virgule valide la commande comme un saut de ligne
```



Comme la série est stationnaire, elle est intégrée d'ordre $d = 0$.

Les fonctions d'autocorrélation totales sont significatives (i.e. plus grandes que les bornes $\pm 1,96/\sqrt{n}$ de l'intervalle de confiance d'un test de nullité de l'autocorrélation à un seuil de 95%) jusqu'à $q^* = 2$ et les autocorrélations partielles jusqu'à $p^* = 3$. Si y suit un $\text{ARIMA}(p,d,q)$, elle suit donc au plus un $\text{ARIMA}(p^* = 3, d^* = 0, q^* = 2)$, que l'on peut estimer.

```
arima(y,c(3,0,2)) #régresse l'ARIMA(3,0,2) pour la série y
```

```
Call:
```

```
arima(x = y, order = c(3, 0, 2))
```

Coefficients:

	ar1	ar2	ar3	ma1	ma2	intercept
	-0.307	0.2091	0.1748	0.0178	-0.0390	0.0008
s.e.	0.542	0.2490	0.1604	0.5488	0.3081	0.0368

```
sigma^2 estimated as 0.2234: log likelihood = -123.32, aic = 260.64
```

Le modèle est valide si ses résidus ne sont pas autocorrélés. On peut le tester en utilisant par exemple le test de Ljung-Box de l'hypothèse nulle de nullité jointe des autocorrélations jusqu'à un ordre k donné (donc absence d'autocorrélation), dont la statistique de test :

$$Q(k) = n(n+2) \sum_{\ell=1}^k \frac{\hat{\rho}_{\ell}^2}{n-\ell}$$

suit une loi du χ^2 à $k - p - q$ degrés de liberté (simplement k degrés de libertés le test est effectué sur des données observables), où n est le nombre d'observations, k le nombre de retards à tester et $\hat{\rho}_{\ell}$ l'autocorrélation empirique d'ordre ℓ .

Par exemple, pour $k = 6$ (comme $p + q = 5$, on ne peut effectuer le test pour $k < 6$) :

```
arima302 <- arima(y,c(3,0,2)) #enregistre les résultats de l'estimation
```

```
Box.test(arima302$residuals, lag=6, type="Ljung-Box", fitdf=5) #test de Ljung-Box
```

Box-Ljung test

```
data: arima302$residuals
X-squared = 0.40607, df = 1, p-value = 0.524
```

L'hypothèse nulle n'est pas rejetée à un seuil de 95% ($p\text{-value} > 0.05$), on dira donc que les résidus ne sont pas autocorrélés jusqu'à 6 retards. Pour nous assurer de l'absence d'autocorrélation, nous la testons pour deux périodicités, c'est-à-dire jusqu'à 24 retards ici.

```
Qtests <- function(series, k, fitdf=0) {
  pvals <- apply(matrix(1:k), 1, FUN=function(l) {
    pval <- if (l<=fitdf) NA else Box.test(series, lag=l, type="Ljung-Box", fitdf=fitdf)$p.value
    return(c("lag"=l,"pval"=pval))
  })
  return(t(pvals))
}
```

```
Qtests(arima302$residuals, 24, 5) #tests de LB pour les ordres 1 à 24
```

	lag	pval
[1,]	1	NA
[2,]	2	NA
[3,]	3	NA
[4,]	4	NA
[5,]	5	NA
[6,]	6	0.5239728
[7,]	7	0.2923972
[8,]	8	0.3708128
[9,]	9	0.3015618
[10,]	10	0.3096879
[11,]	11	0.4154275
[12,]	12	0.5294905
[13,]	13	0.6131866
[14,]	14	0.6179548
[15,]	15	0.6439982
[16,]	16	0.6600634
[17,]	17	0.4385724
[18,]	18	0.5197705
[19,]	19	0.5952434
[20,]	20	0.6660243
[21,]	21	0.5958363
[22,]	22	0.5016374
[23,]	23	0.5460007
[24,]	24	0.5417287

L'absence d'autocorrélation n'est jamais rejetée à 95% jusqu'à 24 retards. Le modèle est donc valide.

Q6. Quels sont les sous-modèles de l'ARIMA(p^*, d^*, q^*) possibles ? Comment peut-on choisir parmi ces sous-modèles ?

Les sous-modèles possibles sont les ARIMA(p, d, q) tels que $p \leq p^*, d \leq d^*, q \leq q^*$.

Dans l'absolu, on cherche un modèle :

- bien ajusté : les coefficients estimés (notamment les coefficients des ordres AR et MA les plus élevés) sont statistiquement significatifs
- valide : les résidus ne sont pas autocorrélés

Passons en revue chacun de ces modèles :

- $p = 3, q = 2$:

Nous avons déjà montré que les résidus de l'ARIMA(3,0,2) ne sont pas autocorrélés, ce modèle est donc valide.

Pour la significativité des coefficients, on peut vérifier qu'on a bien que le rapport entre le coefficient estimé et la variance estimée du coefficient estimé est bien supérieur à sa valeur absolue à 1.96 (ou si la p-value correspondante est inférieure à 0.05) :

```
#fonction de test des significativités individuelles des coefficients
signif <- function(estim){
```

```

coef <- estim$coef
se <- sqrt(diag(estim$var.coef))
t <- coef/se
pval <- (1-pnorm(abs(t)))*2
return(rbind(coef,se,pval))
}

signif(arima302) #tests de significativité de l'ARIMA(3,0,2)
      ar1      ar2      ar3      ma1      ma2      intercept
coef -0.3069992 0.2090601 0.1747649 0.01781536 -0.03904574 0.0008088382
se    0.5420440 0.2489709 0.1603828 0.54880708 0.30813266 0.0368461190
pval  0.5711401 0.4010784 0.2758570 0.97410364 0.89916415 0.9824864146

```

Les coefficients des retards les plus élevés AR(3) et MA(2) ne rejettent chacun pas leur nullité à 95% (p-value>0.05), le modèle ARIMA(3,0,2) est donc mal ajusté.

On cherche à appliquer une procédure similaire aux sous-modèles ARIMA candidats.

```

##fonction d'affichage des tests pour la sélection du modèle ARIMA
arimafit <- function(estim){
adjust <- round(signif(estim),3)
pvals <- Qtests(estim$residuals,24,length(estim$coef)-1)
pvals <- matrix(apply(matrix(1:24,nrow=6),2,function(c) round(pvals[c,],3)),nrow=6)
colnames(pvals) <- rep(c("lag", "pval"),4)
cat("tests de nullité des coefficients :\n")
print(adjust)
cat("\n tests d'absence d'autocorrélation des résidus : \n")
print(pvals)
}

```

- $p = 1, q = 0$:

```

estim <- arima(y,c(1,0,0)); arimafit(estim)
tests de nullité des coefficients :
      ar1 intercept
coef -0.309   -0.002
se    0.071    0.027
pval  0.000    0.955

tests d'absence d'autocorrélation des résidus :
      lag  pval lag  pval lag  pval lag  pval
[1,]   1   NA   7 0.082  13 0.209  19 0.205
[2,]   2 0.016   8 0.109  14 0.224  20 0.252
[3,]   3 0.015   9 0.077  15 0.203  21 0.184
[4,]   4 0.039  10 0.093  16 0.235  22 0.159
[5,]   5 0.064  11 0.127  17 0.128  23 0.182
[6,]   6 0.096  12 0.168  18 0.166  24 0.171

```

Le modèle est bien ajusté (le coefficient AR(1) est significatif) mais n'est pas valide (les résidus sont autocorrélés car Q(1) à Q(3) rejettent l'absence d'autocorrélation).

- $p = 2, q = 0$:

```

estim <- arima(y,c(2,0,0)); arimafit(estim)
tests de nullité des coefficients :
      ar1  ar2 intercept
coef -0.267 0.133   -0.001
se    0.074 0.073    0.031
pval  0.000 0.071    0.985

tests d'absence d'autocorrélation des résidus :
      lag  pval lag  pval lag  pval lag  pval
[1,]   1   NA   7 0.230  13 0.469  19 0.393
[2,]   2   NA   8 0.295  14 0.481  20 0.444
[3,]   3 0.041   9 0.231  15 0.477  21 0.343
[4,]   4 0.116  10 0.246  16 0.485  22 0.329
[5,]   5 0.170  11 0.314  17 0.281  23 0.370
[6,]   6 0.247  12 0.396  18 0.344  24 0.363

```

Le modèle n'est pas bien ajusté (le coefficient AR(2) n'est pas significatif).

- $p = 3, q = 0$:

```
estim <- arima(y,c(3,0,0)); arimafit(estim)
tests de nullité des coefficients :
      ar1  ar2  ar3 intercept
coef -0.289 0.177 0.161      0.001
se    0.073 0.075 0.073      0.037
pval  0.000 0.019 0.028      0.983

tests d'absence d'autocorrélation des résidus :
lag pval lag pval lag pval lag pval
[1,] 1 NA 7 0.653 13 0.790 19 0.737
[2,] 2 NA 8 0.681 14 0.786 20 0.792
[3,] 3 NA 9 0.567 15 0.799 21 0.730
[4,] 4 0.697 10 0.545 16 0.804 22 0.644
[5,] 5 0.872 11 0.640 17 0.602 23 0.682
[6,] 6 0.922 12 0.732 18 0.674 24 0.676
```

Le modèle est bien ajusté (le coefficient AR(3) est significatif) et valide (l'absence d'autocorrélation n'est jamais rejetée). On le garde donc comme modèle candidat.

```
ar3 <- estim
```

- $p = 0, q = 1$:

```
estim <- arima(y,c(0,0,1)); arimafit(estim)
tests de nullité des coefficients :
      ma1 intercept
coef -0.222 -0.002
se    0.059 0.028
pval  0.000 0.957

tests d'absence d'autocorrélation des résidus :
lag pval lag pval lag pval lag pval
[1,] 1 NA 7 0.024 13 0.075 19 0.073
[2,] 2 0.001 8 0.039 14 0.093 20 0.097
[3,] 3 0.003 9 0.025 15 0.077 21 0.072
[4,] 4 0.007 10 0.029 16 0.087 22 0.068
[5,] 5 0.014 11 0.040 17 0.040 23 0.085
[6,] 6 0.024 12 0.055 18 0.055 24 0.073
```

Le modèle est bien ajusté (MA(1) est significatif) mais n'est pas valide (l'absence d'autocorrélation est rejetée par au moins un des tests).

- $p = 0, q = 2$:

```
estim <- arima(y,c(0,0,2)); arimafit(estim)
tests de nullité des coefficients :
      ma1  ma2 intercept
coef -0.297 0.254      0.000
se    0.074 0.067      0.033
pval  0.000 0.000      0.998

tests d'absence d'autocorrélation des résidus :
lag pval lag pval lag pval lag pval
[1,] 1 NA 7 0.665 13 0.801 19 0.741
[2,] 2 NA 8 0.701 14 0.800 20 0.790
[3,] 3 0.629 9 0.604 15 0.803 21 0.715
[4,] 4 0.860 10 0.579 16 0.803 22 0.659
[5,] 5 0.769 11 0.662 17 0.614 23 0.694
[6,] 6 0.846 12 0.746 18 0.684 24 0.692
```

Le modèle est bien ajusté (MA(2) est significatif) et valide (l'absence d'autocorrélation n'est jamais rejetée). On le garde donc comme modèle candidat.

```
ma2 <- estim
```

- $p = 1, q = 1$:

```
estim <- arima(y,c(1,0,1)); arimafit(estim)
```

tests de nullité des coefficients :

	ar1	ma1	intercept
coef	-0.495	0.201	-0.001
se	0.146	0.157	0.029
pval	0.001	0.201	0.966

tests d'absence d'autocorrélation des résidus :

	lag	pval	lag	pval	lag	pval	lag	pval
[1,]	1	NA	7	0.106	13	0.280	19	0.255
[2,]	2	NA	8	0.144	14	0.295	20	0.305
[3,]	3	0.012	9	0.106	15	0.279	21	0.221
[4,]	4	0.043	10	0.125	16	0.307	22	0.203
[5,]	5	0.073	11	0.169	17	0.166	23	0.232
[6,]	6	0.114	12	0.225	18	0.213	24	0.223

Le modèle n'est pas bien ajusté (MA(1) non significatif).

- $p = 2, q = 1$:

```
estim <- arima(y,c(2,0,1)); arimafit(estim)
```

tests de nullité des coefficients :

	ar1	ar2	ma1	intercept
coef	0.202	0.302	-0.476	0.001
se	0.202	0.082	0.202	0.037
pval	0.317	0.000	0.018	0.985

tests d'absence d'autocorrélation des résidus :

	lag	pval	lag	pval	lag	pval	lag	pval
[1,]	1	NA	7	0.362	13	0.586	19	0.503
[2,]	2	NA	8	0.418	14	0.593	20	0.561
[3,]	3	NA	9	0.317	15	0.595	21	0.441
[4,]	4	0.221	10	0.329	16	0.603	22	0.398
[5,]	5	0.405	11	0.415	17	0.369	23	0.435
[6,]	6	0.493	12	0.510	18	0.442	24	0.428

Le modèle est bien ajusté (AR(2) et MA(1) significatifs) et valide (l'absence d'autocorrélation n'est jamais rejetée). On le garde donc comme modèle candidat.

```
ar2ma1 <- estim
```

- $p = 1, q = 2$:

```
estim <- arima(y,c(1,0,2)); arimafit(estim)
```

tests de nullité des coefficients :

	ar1	ma1	ma2	intercept
coef	0.338	-0.628	0.327	0.001
se	0.332	0.327	0.095	0.037
pval	0.308	0.055	0.001	0.987

tests d'absence d'autocorrélation des résidus :

	lag	pval	lag	pval	lag	pval	lag	pval
[1,]	1	NA	7	0.563	13	0.721	19	0.687
[2,]	2	NA	8	0.617	14	0.750	20	0.743
[3,]	3	NA	9	0.488	15	0.754	21	0.646
[4,]	4	0.571	10	0.466	16	0.746	22	0.569
[5,]	5	0.587	11	0.560	17	0.544	23	0.607
[6,]	6	0.749	12	0.650	18	0.619	24	0.604

Le modèle n'est pas bien ajusté (AR(2) non significatif).

- $p = 2, q = 2$:

tests de nullité des coefficients :

	ar1	ar2	ma1	ma2	intercept
coef	0.289	0.092	-0.583	0.246	0.001
se	0.268	0.177	0.266	0.176	0.037
pval	0.282	0.602	0.029	0.163	0.983

tests d'absence d'autocorrélation des résidus :

	lag	pval	lag	pval	lag	pval	lag	pval
[1,]	1	NA	7	0.433	13	0.669	19	0.635
[2,]	2	NA	8	0.498	14	0.691	20	0.696
[3,]	3	NA	9	0.396	15	0.703	21	0.591
[4,]	4	NA	10	0.387	16	0.702	22	0.515
[5,]	5	0.421	11	0.488	17	0.485	23	0.553
[6,]	6	0.636	12	0.590	18	0.563	24	0.552

Le modèle n'est pas bien ajusté (AR(2) et MA(2) non significatifs).

Nous avons donc 3 sous-modèles bien ajustés et valides : ARIMA(3,0,0), ARIMA(0,0,2) et ARIMA(2,0,1). Parmi ces derniers, on pourrait utiliser un critère d'information, tel que l'AIC ou le BIC (qui dépendent négativement de la log-vraisemblance du modèle pénalisée par le nombre de paramètres à estimer) :

```
models <- c("ar3","ma2","ar2ma1"); names(models) <- models
apply(as.matrix(models),1, function(m) c("AIC"=AIC(get(m)), "BIC"=BIC(get(m))))
```

	ar3	ma2	ar2ma1
AIC	260.6771	255.5774	258.6039
BIC	270.3219	268.4371	274.6786

L'ARIMA(0,0,2) minimise à la fois l'AIC et le BIC, il serait donc le meilleur selon ces critères.

- Q7. Pour chacun de ces sous-modèles possibles, effectuez une prévision à 4 mois de la série *desaison* et *xm*. Comparer les résultats obtenus avec les 4 dernières observations de "Données1.csv". Qu'en déduisez-vous sur les modèles proposés ?

```
##création de séries où à chaque colonne sera assignée la prédiction par un modèle
models <- c("ar3","ma2","ar2ma1")
preds <- zoo(matrix(NA,ncol=3,nrow=4),order.by=tail(index(xm.source),4))
colnames(preds) <- models
desaisomp <- preds #séries vierges pour les prédiction de desaison
xmp <- preds #séries vierges pour les prédiction de xm
```

Les modèles ARIMA ont été estimés sur les valeurs centrées y . On ajoute donc aux prédictions de ces modèles la moyenne empirique de *desaison* pour obtenir la prévision de *desaison* :

$$\widehat{desaison}_t = \bar{y} + \hat{y}_t$$

On avait $desaison_t = xm_t - xm_{t-12}$, on a donc :

$$\widehat{xm}_t = xm_{t-12} + \widehat{desaison}_t$$

```
##prédiction de desaison et xm par chaque modèle
for (m in models){
  pred1 <- mean(desaison) + zoo(predict(get(m),4)$pred, order.by=tail(index(xm.source),4))
  pred2 <- as.numeric(tail(xm,12))[1:4] + pred1
  desaisomp[,m] <- pred1
  xmp[,m] <- pred2
}
obs <- tail(xm.source,4) #4 dernières observations de la série originelle
cbind(obs,xmp) #affichage des observations et des prédictions
```

	obs	ar3	ma2	ar2ma1
197	42.76067	42.82602	42.79939	42.83095
198	41.53919	42.30683	42.31568	42.29020
199	54.52629	55.33157	55.31540	55.31388
200	46.65552	46.11783	46.11303	46.14641

Pour comparer la performance prédictive des modèles sélectionnés, calculons le écart moyen entre l'observation et la prédiction (RMSE ou *root mean squared error*) que l'on normalisera avec l'écart-type de la série.

```
apply(xmp,2, function(x) sqrt(sum((x-obs)^2)/4)/sd(xm.source)) #calcul des RMSE
```


	ar3	ma2	ar2ma1
	0.1188310	0.1184545	0.1155785

L'ARIMA(2,0,1) a le RMSE le plus faible et donne donc la meilleur prévision de la série originelle.

Q8. En suivant une démarche analogue, proposer un modèle pour la série contenue dans le fichier "Donnees2.csv".



```
datafile <- "Donnees2.csv" #définit le fichier de données

data <- read.csv(datafile,sep=";") #importe un fichier .csv dans un objet de classe data.frame
xm.source <- zoo(data[[1]]) #convertit le premier élément de data en série temporelle de type "zoo"
T <- length(xm.source)
xm <- xm.source[1:(T-4)] #supprime les 4 dernières valeurs
dev.off() #réinitialise les paramètres de graphique
plot(xm)
```



La série semble présenter une tendance linéaire. Corrigons cette tendance pour y voir plus clair.

```
trend <- 1:length(xm)
lt <- lm(xm ~ trend) #régresse la série sur une constante et une tendance linéaire
summary(lt) #affiche un résumé de la régression
r <- lt$residuals #on garde la série corrigée de sa tendance
par(mfrow=c(1,2))
plot(r)
acf(r)
```



La série ne semble pas présenter de stationnarité.

```
pp.test(xm)
```



Phillips-Perron Unit Root Test

```
data: xm
Dickey-Fuller Z(alpha) = -58.438, Truncation lag parameter = 4, p-value = 0.01
alternative hypothesis: stationary
```

La série rejette la racine unitaire, donc on dira qu'elle est stationnaire, i.e. $d=0$.

Remarque : la série est très persistante, ce qui posera problème par la suite

```
### pour l'intérêt de l'exercice (et des temps de calculs), on n'ira pas plus loin que 24 retards
acf(r,24);pacf(r,24)
```



On choisira $p \leq 4$ et $q \leq 21$.

pmax=4; qmax=21

Remarque : si on regardait plus retards, les autocorrélations redeviennent significatives jusqu'à un ordre très très élevé (essayez `acf(r,150)`).

```
## fonction pour estimer un arima et en vérifier l'ajustement et la validité
modelchoice <- function(p,q,data=r, k=24){
  estim <- try(arima(data, c(p,0,q),optim.control=list(maxit=20000)))
  if (class(estim)=="try-error") return(c("p"=p,"q"=q,"arsignif"=NA,"masignif"=NA,"resnocorr"=NA, "ok"=NA))
  arsignif <- if (p==0) NA else signif(estim)[3,p]<=0.05
  masignif <- if (q==0) NA else signif(estim)[3,p+q]<=0.05
  resnocorr <- sum(Qtests(estim$residuals,24,length(estim$coef)-1)[,2]<=0.05,na.rm=T)==0
  checks <- c(arsignif,masignif,resnocorr)
  ok <- as.numeric(sum(checks,na.rm=T)==(3-sum(is.na(checks))))
  return(c("p"=p,"q"=q,"arsignif"=arsignif,"masignif"=masignif,"resnocorr"=resnocorr,"ok"=ok))
}

## fonction pour estimer et vérifier tous les arima(p,q) avec p<=pmax et q<=max
armamodelchoice <- function(pmax,qmax){
  pqs <- expand.grid(0:pmax,0:qmax) t(apply(matrix(1:dim(pqs)[1]),1,function(row) {
  p <- pqs[row,1]; q <- pqs[row,2]
  cat(paste0("Computing ARMA(",p,",",",q,") \n"))
  modelchoice(p,q)
  })))
}
```

armamodels <- armamodelchoice(pmax,qmax) #estime tous les arima (patienter...)

selec <- armamodels[armamodels[, "ok"] == 1 & !is.na(armamodels[, "ok"]),] #modèles bien ajustés et valides

```
selec
  p  q arsignif masignif resnocorr ok
[1,] 2  1      1      1      1  1
[2,] 0 10      NA      1      1  1
[3,] 2 14      1      1      1  1
[4,] 4 14      1      1      1  1
[5,] 1 18      1      1      1  1
```

On a 8 modèles bien ajustés et valides.

```
pqs <- apply(selec,1,function(row) list("p"=as.numeric(row[1]),"q"=as.numeric(row[2]))) #crée
#une liste des ordres p et q des modèles candidats
names(pqs) <- paste0("arma(",selec[,1],",",selec[,2],")") #renomme les éléments de la liste
models <- lapply(pqs, function(pq) arima(r,c(pq[["p"]],0,pq[["q"]])) #crée une liste des modèles
vapply(models, FUN.VALUE=numeric(2), function(m) c("AIC"=AIC(m),"BIC"=BIC(m))) #calcule les AIC et
#BIC des modèles candidats
      arma(2,1) arma(0,10) arma(2,14) arma(4,14) arma(1,18)
AIC  258.2550  269.7291  271.0639  270.5061  272.5334
BIC  274.5163  308.7564  329.6048  335.5516  340.8312
```

L'ARIMA(2,0,1) minimise les critères d'information.

```
rps <- lapply(models, function(m) as.zoo(predict(m,4)$pred) #prévisions de r
xmps <- lapply(rps, function(rp) rp+cbind(1,c((T-3):T))%*%lt$coefficients) #prévisions de xm
rmse <- vapply(xmps, FUN.VALUE=numeric(1), function(xmp) sqrt(sum((as.zoo(xmp)-tail(xm.source,4))^2)))
#calcule les rmse out-of-sample
rmse
      arma(2,1) arma(0,10) arma(2,14) arma(4,14) arma(1,18)
0.7131456  1.0280417  1.1187613  1.2403910  1.2118350
```

L'ARIMA(2,0,1) fait aussi la meilleure prévision hors échantillon.