

Econométrie 2

Chapitre 2 : données de panel.

ENSAE 2021-2022

Michael Visser

CREST-ENSAE

Introduction

Exogénéité des résidus mais autocorrélation

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall(t, t')$ (exogénéité stricte)

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall t' \geq t$ (exogénéité faible)

Exemple : effet de la police sur la criminalité

- ▶ Panel = échantillon d'unités (individus, entreprises...) suivies dans le temps.
- ▶ Deux intérêts principaux :
 1. résoudre (ou limiter) le problème d'endogénéité ;
 2. étudier la dynamique et séparer la dépendance d'état de l'hétérogénéité inobservée.
- ▶ Un problème : l'attrition endogène. Cf. chapitre sur le problème de sélection.
- ▶ On notera Y_{it} la variable expliquée et X_{it} le vecteur (dimension $K \times 1$) des variables explicatives de l'unité i en t .
- ▶ On supposera toujours $(Y_{i1}, X_{i1}, \dots, Y_{iT}, X_{iT})_{i=1 \dots n}$ i.i.d. Mais (Y_{is}, X_{is}) sera en général corrélé à (Y_{it}, X_{it}) , pour $s \neq t$.

- Modèle de base :

$$Y_{it} = X'_{it}\beta_0 + \nu_{it}$$

pour $i = 1 \dots n$ et $t = 1 \dots T$.

- Asymptotique en n , pas en T . Hypothèse pas toujours évidente (en macroéconomie, on peut avoir $n = 70$ pays et $T = 50$ périodes).
- Le résidu sera souvent décomposé en deux termes : $\nu_{it} = \alpha_i + \varepsilon_{it}$.
- α_i est l'« effet individuel ». Agrège les facteurs inobservés constant dans le temps. .
- ε_{it} , souvent appelé « choc idiosyncratique », agrège les facteurs inobservés variables dans le temps.
- On supposera dans la suite au moins l'*exogénéité faible* :

$$E(X_{it}\varepsilon_{it'}) = 0, \forall t' \geq t. \quad (1)$$

- ▶ α_i est souvent appelé « effet fixe » ou « effet aléatoire ».
- ▶ Dans la littérature économétrique on considère α_i soit comme un paramètre fixe, comme β_0 , soit comme une variable aléatoire, comme ε_{it} .
- ▶ Souvent plus simple de le supposer aléatoire : c'est l'approche adoptée dans ce cours.
- ▶ La question essentielle est alors : α_i est-il corrélé à X_{it} ?
- ▶ Si l'on suppose $E(X_{it}\alpha_i) = 0$, alors il n'y a pas d'endogénéité et les MCO sont convergents.
- ▶ Mais les estimateurs habituels des écarts-types ne sont pas convergents (à cause de l'autocorrélation des résidus) \Rightarrow correction nécessaire sinon inférence incorrecte.
- ▶ Si, $E(X_{it}\alpha_i) \neq 0$, les panels peuvent permettre de résoudre le problème d'endogénéité.
- ▶ Mais on ne pourra pas inclure dans X_{it} des variables constantes dans le temps car on ne pourra séparer leur effet de α_i .

Introduction

Exogénéité des résidus mais autocorrélation

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall(t, t')$ (exogénéité stricte)

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall t' \geq t$ (exogénéité faible)

Exemple : effet de la police sur la criminalité

- ▶ Exemple : i = classe, t = élève, Y_{it} = note à un examen, X_{it} = âge, sexe, diplôme des parents...
- ▶ Probablement $E(\nu_{is}\nu_{it}) \neq 0$, du fait par exemple d'« effet profs ».
- ▶ Mais $E(X_{it}\nu_{it}) = 0$ reste crédible, en particulier si les professeurs sont affectés aléatoirement aux classes.
- ▶ On a :

$$\begin{aligned}\hat{\beta}_{MCO} &= \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} X'_{it} \right]^{-1} \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} Y_{it} \right] \\ &= \beta_0 + \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} X'_{it} \right]^{-1} \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \right].\end{aligned}$$

- ▶ Il s'agit de l'estimateur standard obtenu à partir des nT observations (en anglais : pooled OLS estimator).

- Sous la seule hypothèse $E(X_{it}\nu_{it}) = 0$ et d'échantillonnage i.i.d. d'unités, l'estimateur est convergent et asymptotiquement normal mais il faut adapter l'estimateur des écarts-types.
- Soit (en omettant l'indice i) $J = E \left[\frac{1}{T} \sum_{t=1}^T X_t X_t' \right]$. Alors :

$$\sqrt{n}(\hat{\beta}_{MCO} - \beta_0) \xrightarrow{d} \mathcal{N} \left(0, J^{-1} E \left[\left(\frac{1}{T} \sum_{t=1}^T X_t \nu_t \right) \left(\frac{1}{T} \sum_{t=1}^T X_t \nu_t \right)' \right] J^{-1} \right).$$

- Preuve : on a

$$\begin{aligned} \sqrt{n}(\hat{\beta}_{MCO} - \beta_0) &= \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} X_{it}' \right]^{-1} \left[\frac{1}{\sqrt{nT}} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \right] \\ &= J^{-1} \left[\frac{1}{\sqrt{nT}} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \right] + \left[\left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} X_{it}' \right]^{-1} - J^{-1} \right] \left[\frac{1}{\sqrt{nT}} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \right]. \end{aligned}$$

D'après le TCL on a

$$\frac{1}{\sqrt{nT}} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \xrightarrow{d} \mathcal{N}(0, B)$$

où

$$\begin{aligned} B &= V \left(\frac{1}{T} \sum_{t=1}^T X_{it} \nu_{it} \right) \\ &= E \left[\left(\frac{1}{T} \sum_{t=1}^T X_{it} \nu_{it} \right) \left(\frac{1}{T} \sum_{t=1}^T X_{it} \nu_{it} \right)' \right]. \end{aligned}$$

Donc

$$\frac{1}{\sqrt{n}T} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} = O_p(1)$$

ce qui donne

$$\begin{aligned} \sqrt{n} \left(\hat{\beta}_{MCO} - \beta_0 \right) &= J^{-1} \left[\frac{1}{\sqrt{n}T} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \right] + o_p(1) O_p(1) \\ &= J^{-1} \left[\frac{1}{\sqrt{n}T} \sum_{i=1}^n \sum_{t=1}^T X_{it} \nu_{it} \right] + o_p(1). \end{aligned}$$

On en déduit finalement que

$$\sqrt{n} \left(\hat{\beta}_{MCO} - \beta_0 \right) \xrightarrow{d} \mathcal{N} \left(0, J^{-1} B J^{-1} \right).$$

Dans cette preuve, nous avons utilisé plusieurs définitions et propriétés de la théorie asymptotique en stat/proba (voir par exemple Wooldridge, chapitre 3) :

1. Une séquence de variables aléatoires (scalaires) $\{a_n\}_{n=1}^{\infty}$ converge en probabilité vers une constante a si pour tout $\varepsilon > 0$ on a $P(|a_n - a| > \varepsilon) \rightarrow 0$ lorsque $n \rightarrow \infty$. On écrit alors $a_n \xrightarrow{P} a$ ou $\text{plim}(a_n) = a$. Lorsque $a = 0$, on dit que $\{a_n\}$ est $o_p(1)$, noté $a_n = o_p(1)$.
2. Une séquence $\{a_n\}_{n=1}^{\infty}$ est bornée en probabilité si pour tout $\varepsilon > 0$ il existe un nombre réel $b_\varepsilon < \infty$ et un nombre entier n_ε tel que $P(|a_n| \geq b_\varepsilon) < \varepsilon$ pour tout $n > n_\varepsilon$. On écrit alors $a_n = O_p(1)$.
3. Lorsque une séquence $\{a_n\}_{n=1}^{\infty}$ converge en loi vers une variable aléatoire a , noté $a_n \xrightarrow{d} a$, on a $a_n = O_p(1)$.
4. Lorsque les séquences $\{a_n\}_{n=1}^{\infty}$ et $\{b_n\}_{n=1}^{\infty}$ sont telles que $a_n = o_p(1)$ et $b_n = O_p(1)$, alors $a_n b_n = o_p(1)$.
5. Si $a_n \xrightarrow{d} a$ et $b_n - a_n \xrightarrow{P} 0$, alors $b_n \xrightarrow{d} a$.
6. Ces différentes définitions et propriétés s'appliquent également lorsque $\{a_n\}_{n=1}^{\infty}$ et $\{b_n\}_{n=1}^{\infty}$ sont des séquences de vecteurs ou matrices aléatoires.

- L'élément de la $(l + 1)$ -ème ligne et $(j + 1)$ -ème colonne de B s'écrit

$$B_{l+1,j+1} = E \left[\left(\frac{1}{T} \sum_{t=1}^T X_{ilt} \nu_{it} \right) \left(\frac{1}{T} \sum_{t=1}^T X_{ijt} \nu_{it} \right) \right]$$

où X_{ilt} (resp. X_{ijt}) est le l -ème (resp. j -ème) élément de X_{it} .

- On n'impose aucune restriction sur $B_{l+1,j+1}$. En particulier on ne fait pas l'hypothèse d'homoscédasticité, c'est à dire

$$E (X_{ilt} X_{ijt} \nu_{it}^2) = E (X_{ilt} X_{ijt}) E (\nu_{it}^2) = E (X_{ilt} X_{ijt}) \sigma^2$$

ni l'hypothèse de non-corrélation entre les termes d'erreur (conditionnellement aux variables explicatives), c'est à dire

$$E (X_{ilt} \nu_{it} X_{ijs} \nu_{is}) = 0$$

pour tout $s \neq t$.

- ▶ La variance asymptotique $J^{-1}BJ^{-1}$ peut s'estimer de manière convergente par

$$\hat{V} = \hat{J}^{-1} \left[\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{T} \sum_{t=1}^T X_{it} \hat{\nu}_{it} \right) \left(\frac{1}{T} \sum_{t=1}^T X_{it} \hat{\nu}_{it} \right)' \right] \hat{J}^{-1},$$

avec $\hat{J} = \frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T X_{it} X_{it}'$ et $\hat{\nu}_{it} = Y_{it} - X_{it} \hat{\beta}_{MCO}$.

- ▶ Cet estimateur est convergent et robuste (i) à l'hétéroscédasticité, et (ii) à l'autocorrélation de ν (i.e., $\text{Cov}(\nu_{is}, \nu_{it}) \neq 0$).
- ▶ On peut obtenir de tels écarts-types avec l'option `cluster` de Stata (voir l'application à la fin de ce chapitre).

Introduction

Exogénéité des résidus mais autocorrélation

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall(t, t')$ (exogénéité stricte)

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall t' \geq t$ (exogénéité faible)

Exemple : effet de la police sur la criminalité

- ▶ Jusqu'à la fin de ce chapitre on enlève explicitement la constante de X_{it} . Donc $X_{it} = (X_{i1t}, \dots, X_{iK-1t})'$ est maintenant de dimension $(K-1) \times 1$. Le modèle s'écrit alors comme

$$Y_{it} = \delta_0 + X_{it}'\beta_0 + \alpha_i + \varepsilon_{it},$$

où δ_0 est la constante et β_0 est un vecteur de dimension $(K-1) \times 1$.

- ▶ Supposons que $E(X_{it}'\alpha_i) \neq 0$ mais que l'hypothèse d'*exogénéité stricte* est vérifiée, i.e. $E(X_{it}\varepsilon_{it'}) = 0 \forall (t, t') \in \{1, \dots, T\}^2$.
- ▶ Les 2 exemples suivants montrent que l'exogénéité stricte est parfois restrictive.
- ▶ 1er exemple : Y_{it} = salaire, X_{it} = expérience spécifique (temps passé dans la dernière entreprise), α_i = capacités inobservées de l'individu.
- ▶ X_{it} a priori non corrélé aux chocs futurs, non anticipables, de salaire \Rightarrow exogénéité faible crédible.
- ▶ Mais X_{it} peut être corrélé aux chocs passés, si l'on décide de rester en fonction de son salaire passé.

- 2ème exemple : $X_{it} = Y_{it-1}$. Dans ce cas, on a, par exemple si ε_{it} i.i.d. et $E(\alpha_i \varepsilon_{it}) = 0 \forall t$,

$$\begin{aligned} E(X_{it} \varepsilon_{it-1}) &= E(Y_{it-1} \varepsilon_{it-1}) = E[(\delta_0 + \beta_{01} Y_{it-2} + \alpha_i + \varepsilon_{it-1}) \varepsilon_{it-1}] \\ &= E(\varepsilon_{it-1}^2) \neq 0 \end{aligned}$$

et de même $E(X_{it'} \varepsilon_{it-1}) \neq 0$ en général pour $t' > t$. En revanche, l'exogénéité faible est bien satisfaite :

$$E(X_{it} \varepsilon_{it'}) = E(Y_{it-1} \varepsilon_{it'}) = 0, \forall t' \geq t$$

car Y_{it-1} ne dépend que de α_i et des termes d'erreur passés ε_{it} pour $t < t'$.

- ▶ Deux estimateurs classiques : l'estimateur within et l'estimateur par différences premières.
- ▶ Idée commune : obtenir une équation où l'on s'est débarrassé du α_i .
- ▶ Différences premières : on a, en notant $\Delta U_{it} = U_{it} - U_{it-1}$ pour toute variable U ,

$$\Delta Y_{it} = \Delta X'_{it} \beta_0 + \Delta \varepsilon_{it}. \quad (2)$$

- ▶ Remarquons que sous l'hypothèse d'exogénéité stricte :

$$E[\Delta X_{it} \Delta \varepsilon_{it}] = E[X_{it} \varepsilon_{it}] - E[X_{it} \varepsilon_{it-1}] - E[X_{it-1} \varepsilon_{it}] + E[X_{it-1} \varepsilon_{it-1}] = 0.$$

- ▶ Dans (2), les régresseurs sont exogènes et on peut les estimer de manière convergente par les MCO des données empilées (en utilisant $n(T-1)$ observations car on perd la première observation pour chaque unité i).

Estimateur des différences premières : propriétés

- ▶ Omettons l'indice i . On a $E[\Delta X_t \Delta Y_t] = E[\Delta X_t \Delta X'_t] \beta_0$ donc, si $J_{FD} = E\left[\frac{1}{T-1} \sum_{t=2}^T \Delta X_t \Delta X'_t\right]$ est de plein rang,

$$\beta_0 = J_{FD}^{-1} E\left[\frac{1}{T-1} \sum_{t=2}^T \Delta X_t \Delta Y_t\right].$$

- ▶ Comme les MCO, l'estimateur des différences premières vérifie

$$\begin{aligned}\hat{\beta}_{FD} &= \left[\frac{1}{n(T-1)} \sum_{i=1}^n \sum_{t=2}^T \Delta X_{it} \Delta X'_{it} \right]^{-1} \left[\frac{1}{n(T-1)} \sum_{i=1}^n \sum_{t=2}^T \Delta X_{it} \Delta Y_{it} \right] \\ &= \beta_0 + \left[\frac{1}{n(T-1)} \sum_{i=1}^n \sum_{t=2}^T \Delta X_{it} \Delta X'_{it} \right]^{-1} \left[\frac{1}{n(T-1)} \sum_{i=1}^n \sum_{t=2}^T \Delta X_{it} \Delta \varepsilon_{it} \right].\end{aligned}$$

- ▶ Sous les hypothèses d'exogénéité stricte et d'échantillonnage i.i.d. d'unités, l'estimateur est convergent et (preuve identique à la preuve page 8/9) :

$$\sqrt{n}(\hat{\beta}_{FD} - \beta_0) \xrightarrow{d} \mathcal{N}\left(0, J_{FD}^{-1} E\left[\left(\frac{1}{T-1} \sum_{t=2}^T \Delta X_t \Delta \varepsilon_t\right) \left(\frac{1}{T-1} \sum_{t=2}^T \Delta X_t \Delta \varepsilon_t\right)'\right] J_{FD}^{-1}\right).$$

- On peut estimer la matrice de variance asymptotique par

$$\hat{V} = \left[\frac{1}{n(T-1)} \sum_{i=1}^n \sum_{t=2}^T \Delta X_{it} \Delta X'_{it} \right]^{-1} \left[\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{T-1} \sum_{t=2}^T \Delta X_{it} \widehat{\Delta \varepsilon}_{it} \right) \left(\frac{1}{T-1} \sum_{t=2}^T \Delta X_{it} \widehat{\Delta \varepsilon}_{it} \right)' \right] \\ \times \left[\frac{1}{n(T-1)} \sum_{i=1}^n \sum_{t=2}^T \Delta X_{it} \Delta X'_{it} \right]^{-1}.$$

avec $\widehat{\Delta \varepsilon}_{it} = \Delta Y_{it} - \Delta X'_{it} \widehat{\beta}_{FD}$.

- Cet estimateur est convergent et robuste (i) à l'hétéroscédasticité, (ii) à l'autocorrélation de $\Delta \varepsilon$ (i.e., $\text{Cov}(\Delta \varepsilon_s, \Delta \varepsilon_t) \neq 0$).
- $\widehat{\beta}_{FD}$ est efficace asymptotiquement sous l'hypothèse beaucoup plus forte que i) $E(\Delta X_t \Delta \varepsilon_t^2 \Delta X'_t) = E(\Delta \varepsilon_t^2) E(\Delta X_t \Delta X'_t)$ avec $E(\Delta \varepsilon_t^2)$ indépendant de t (hypothèse d'homoscédasticité) ; ii) $E(\Delta X_t \Delta \varepsilon_t \Delta \varepsilon_s \Delta X'_s) = 0$ pour tout $s \neq t$ (hypothèse de non-corrélation entre $\Delta \varepsilon_s$ et $\Delta \varepsilon_t$ conditionnellement à ΔX_t et ΔX_s).

- Sous ces deux hypothèses on obtient

$$E \left[\left(\frac{1}{T-1} \sum_{t=2}^T \Delta X_t \Delta \varepsilon_t \right) \left(\frac{1}{T-1} \sum_{t=2}^T \Delta X_t \Delta \varepsilon_t \right)' \right] = E[(\Delta \varepsilon_t)^2] E \left[\frac{1}{(T-1)^2} \sum_{t=2}^T \Delta X_t \Delta X_t' \right].$$

- Dans ce cas, la variance asymptotique de $\sqrt{n} \left(\hat{\beta}_{FD} - \beta_0 \right)$ se simplifie en $V = E[(\Delta \varepsilon_t)^2] J_{FD}^{-1} / (T-1)$.
- La non-corrélation entre $\Delta \varepsilon_s$ et $\Delta \varepsilon_t$ est satisfaite si $(\varepsilon_t)_t$ suit une marche aléatoire :

$$\varepsilon_{t+1} = \varepsilon_t + \eta_{t+1},$$

où les $(\eta_t)_t$ sont indépendants et $E(\eta_t) = 0$ pour tout t . En effet, dans ce cas $E(\Delta \varepsilon_s \Delta \varepsilon_t | \Delta X_s, \Delta X_t) = E(\eta_{s+1} \eta_{t+1} | \Delta X_s, \Delta X_t) = 0$. Mais si les $(\varepsilon_t)_t$ sont indépendants,

$$\begin{aligned} E(\Delta \varepsilon_t \Delta \varepsilon_{t+1} | \Delta X_t, \Delta X_{t+1}) &= E((\varepsilon_t - \varepsilon_{t-1})(\varepsilon_{t+1} - \varepsilon_t) | \Delta X_t, \Delta X_{t+1}) \\ &= -E(\varepsilon_t^2 | \Delta X_t, \Delta X_{t+1}) < 0. \end{aligned}$$

- ▶ Deuxième estimateur classique : l'estimateur within. On a, en notant, pour toute v.a. U , $\bar{U}_i = \frac{1}{T} \sum_{t=1}^T U_{it}$ et $\tilde{U}_{it} = U_{it} - \bar{U}_i$,

$$\bar{Y}_i = \delta_0 + \bar{X}_i' \beta_0 + \alpha_i + \bar{\varepsilon}_i$$

et donc

$$\tilde{Y}_{it} = \tilde{X}_{it}' \beta_0 + \tilde{\varepsilon}_{it}. \quad (3)$$

- ▶ Là aussi, de par l'exogénéité stricte,

$$E \left[\tilde{X}_{it} \tilde{\varepsilon}_{it} \right] = 0.$$

- ▶ Donc les régresseurs de (3) sont exogènes et β_0 peut être estimé de manière convergente par les MCO empilés : estimateur within.

Estimateur within : propriétés

- ▶ Comme pour les différences premières, on a, en notant

$$J_W = E \left[\frac{1}{T} \sum_{t=1}^T \tilde{X}_t \tilde{X}_t' \right] \text{ (supposée de plein rang),}$$

$$\beta_0 = J_W^{-1} E \left[\frac{1}{T} \sum_{t=1}^T \tilde{X}_t \tilde{Y}_t \right].$$

- ▶ Et l'estimateur within vérifie

$$\begin{aligned} \hat{\beta}_W &= \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T \tilde{X}_{it} \tilde{X}_{it}' \right]^{-1} \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T \tilde{X}_{it} \tilde{Y}_{it} \right] \\ &= \beta_0 + \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T \tilde{X}_{it} \tilde{X}_{it}' \right]^{-1} \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T \tilde{X}_{it} \varepsilon_{it} \right]. \end{aligned}$$

N.B. : on a remplacé $\tilde{\varepsilon}_{it}$ par ε_{it} car $\frac{1}{T} \sum_{t=1}^T \tilde{X}_{it} \bar{\varepsilon}_i = 0$.

- ▶ Ainsi (preuve similaire à celle de la page 8/9) :

$$\sqrt{n} (\hat{\beta}_W - \beta_0) \xrightarrow{d} \mathcal{N} \left(0, J_W^{-1} E \left[\left(\frac{1}{T} \sum_{t=1}^T \tilde{X}_t \varepsilon_t \right) \left(\frac{1}{T} \sum_{t=1}^T \tilde{X}_t \varepsilon_t \right)' \right] J_W^{-1} \right).$$

- ▶ Comme pour les différences premières, on peut estimer de manière robuste cette matrice de variance par

$$\hat{V} = \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T \tilde{X}_{it} \tilde{X}_{it}' \right]^{-1} \left[\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{T} \sum_{t=1}^T \tilde{X}_{it} \hat{\varepsilon}_{it} \right) \left(\frac{1}{T} \sum_{t=1}^T \tilde{X}_{it} \hat{\varepsilon}_{it} \right)' \right] \\ \times \left[\frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T \tilde{X}_{it} \tilde{X}_{it}' \right]^{-1}.$$

avec $\hat{\varepsilon}_{it} = \tilde{Y}_{it} - \tilde{X}_{it}' \hat{\beta}_W$.

- ▶ $\hat{\beta}_W$ est efficace asymptotiquement sous l'hypothèse beaucoup plus forte que

$$E \left[\left(\frac{1}{T} \sum_{t=1}^T \tilde{X}_t \varepsilon_t \right) \left(\frac{1}{T} \sum_{t=1}^T \tilde{X}_t \varepsilon_t \right)' \right] = E[\varepsilon_t^2] E \left[\frac{1}{T^2} \sum_{t=1}^T \tilde{X}_t \tilde{X}_t' \right],$$

qui combine homoscédasticité et non corrélation entre ε_s et ε_t (conditionnellement aux variables explicatives).

- ▶ La variance asymptotique s'écrit alors $V = E[\varepsilon_t^2] J_W^{-1} / T$.

- Pour estimer $E[\varepsilon_t^2] = \sigma_\varepsilon^2$ on utilise que

$$\begin{aligned} E(\tilde{\varepsilon}_{it}^2) &= E(\varepsilon_{it}^2) + E(\bar{\varepsilon}_i^2) - 2E(\varepsilon_{it}\bar{\varepsilon}_i) \\ &= \sigma_\varepsilon^2 + \sigma_\varepsilon^2/T - 2\sigma_\varepsilon^2/T = \sigma_\varepsilon^2(1 - 1/T). \end{aligned}$$

sous l'hypothèse de non-corrélation entre ε_{it} et ε_{is} .

- Donc on a $\frac{1}{T-1} \sum_{t=1}^T E(\tilde{\varepsilon}_{it}^2) = \sigma_\varepsilon^2$.
- Un estimateur convergent (et sans biais) de σ_ε^2 est alors (comme il n'y pas de constante dans le modèle (3), le nombre de paramètres à estimer vaut $K - 1$) :

$$\hat{\sigma}_\varepsilon^2 = \frac{\sum_{i=1}^n \sum_{t=1}^T \hat{\varepsilon}_{it}^2}{(n(T-1) - K + 1)}.$$

- Attention, cet estimateur diffère de l'estimateur habituel de la variance (du terme d'erreur) qu'on obtient à l'issue de MCO de \tilde{Y}_{it} sur \tilde{X}_{it} : $\frac{\sum_{i=1}^n \sum_{t=1}^T \hat{\varepsilon}_{it}^2}{(nT - K + 1)}$ (voir Econométrie 1, Chapitre 3).

- ▶ $\hat{\beta}_{FD}$ et $\hat{\beta}_W$ coïncident quand $T = 2$ mais pas quand $T > 2$.
 - ▶ $\hat{\beta}_W$ sera plus précis lorsque les $(\varepsilon_t)_t$ sont très peu corrélés, $\hat{\beta}_{FD}$ sera meilleur lorsque les $(\varepsilon_t)_t$ sont très corrélés.
 - ▶ Les deux estimateurs sont tous deux convergents et asymptotiquement normaux sous l'hypothèse d'exogénéité stricte.
 - ▶ Mais ils sont en général non convergents sous la seule hypothèse d'exogénéité faible, et convergent vers des limites en général différentes.
- ⇒ s'ils sont très différents, l'hypothèse d'exogénéité stricte est suspecte.

- ▶ Idée : considérons $T = 2$ et le modèle en différence première :

$$\begin{aligned}\Delta Y_2 &= \Delta X_2' \beta_0 + \Delta \varepsilon_2 \\ &= \Delta X_2' \beta_0 + X_2' \gamma_0 + \Delta \varepsilon_2,\end{aligned}\tag{4}$$

avec $\gamma_0 = 0$.

- ▶ Sous l'exogénéité stricte, $E[\Delta X_2 \Delta \varepsilon_2] = 0$ et $E[X_2 \Delta \varepsilon_2] = 0$.
 - ▶ Donc si l'on régresse ΔY_2 sur ΔX_2 et X_2 , les coefficients de X_2 devraient être non significatifs.
 - ▶ Mais sous la seule hypothèse d'exogénéité faible, $E[X_2 \Delta \varepsilon_2] = -E[X_2 \varepsilon_1] \neq 0$ en général.
- ⇒ X_2 endogène dans (4) et $\hat{\gamma}_{MCO}$ ne convergera pas vers 0.
- ▶ Il suffit donc de tester $\gamma_0 = 0$ dans (4).
 - ▶ Idem si $T > 2$: on inclut X_2, \dots, X_T (ou un sous-ensemble de ces régresseurs) dans l'équation en différences premières et on teste leur significativité.

- Sous l'hypothèse d'exogénéité stricte, on a :

$$E [X_{t'} (\Delta Y_t - \Delta X_t' \beta_0)] = E [X_{t'} \Delta \varepsilon_t] = 0$$

$$\forall (t, t') \in \{2, \dots, T\} \times \{1, \dots, T\}.$$

- Cette écriture permet (i) de construire l'estimateur optimal de β_0 sous la condition d'exogénéité stricte et (ii) de tester le modèle, puisqu'on a $(K - 1)(T - 1)T > (K - 1)$ conditions de moment.
- Cette approche est peu utilisée en pratique, car l'estimateur en deux étapes peut être instable quand le nombre de conditions de moments est grand p/r aux nombres de paramètres, comme ici dès que $T \geq 5$.

Introduction

Exogénéité des résidus mais autocorrélation

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall (t, t')$ (exogénéité stricte)

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall t' \geq t$ (exogénéité faible)

Exemple : effet de la police sur la criminalité

- ▶ On suppose maintenant seulement l'exogénéité faible :

$$E(X_{it}\varepsilon_{it'}) = 0 \quad \forall t' \geq t.$$

- ▶ Exemple 1 : modèles dynamiques :

$$Y_{it} = W'_{it}\gamma_0 + Y_{it-1}\rho_0 + \alpha_i + \varepsilon_{it},$$

avec $X_{it} = (W'_{it}, Y_{it-1})'$. Dans ce modèle, par construction l'exogénéité stricte n'est pas vérifiée car $E(X_{it}\varepsilon_{it-1}) \neq 0$.

- ▶ Mais l'exogénéité faible l'est si :
 1. les $(W_{it})_t$ sont faiblement exogènes ;
 2. les $(\varepsilon_{it})_t$ sont non corrélés entre eux, et non corrélés à (α_i, Y_{i0}) .
- ▶ Dans ce cas en effet, on a, pour $t \geq 2$,

$$Y_{it-1} = \left(\sum_{j=0}^{t-2} \rho_0^j W'_{it-1-j} \right) \gamma + Y_{i0} \rho_0^{t-1} + \alpha_i \left(\frac{1 - \rho_0^{t-1}}{1 - \rho_0} \right) + \sum_{j=0}^{t-2} \rho_0^j \varepsilon_{it-1-j}.$$

- ▶ Par conséquent,

$$E[Y_{it-1}\varepsilon_{it'}] = 0 \quad \forall t' \geq t.$$

- ▶ Le modèle précédent permet de distinguer l'hétérogénéité inobservée (α_i) de la dépendance d'état (effet de Y_{it-1}).
- ▶ Exemple 2 : modèle statique avec effets de retour. $X_{it} = (V_{it}, W'_{it})'$ avec :

$$\begin{aligned}Y_{it} &= W'_{it}\gamma_0 + V_{it}\delta_0 + \alpha_i + \varepsilon_{it} \\V_{it} &= W'_{it}\lambda_0 + Y_{it-1}\rho_0 + \zeta_i + \eta_{it}.\end{aligned}$$

- ▶ V_{it} peut par exemple représenter le taux de SIDA dans une ville et Y_{it} les ventes individuelles de préservatifs . Les ventes passées ont a priori un effet sur le taux de SIDA en t .
- ▶ Dans ce modèle, l'exogénéité stricte n'est pas satisfaite sauf si $\rho_0 = 0$ et W_{it} est strictement exogène. Mais l'exogénéité faible l'est toujours sous les mêmes conditions que précédemment.

- L'estimateur des différences premières vérifie :

$$\text{plim} \hat{\beta}_{FD} = \beta_0 + \left[\frac{1}{T-1} \sum_{t=2}^T E(\Delta X_t \Delta X'_t) \right]^{-1} \left[\frac{1}{T-1} \sum_{t=2}^T E(\Delta X_t \Delta \varepsilon_t) \right].$$

- On a par ailleurs :

$$E(\Delta X_t \Delta \varepsilon_t) = E(X_t \varepsilon_t) - E(X_t \varepsilon_{t-1}) - E(X_{t-1} \varepsilon_t) + E(X_{t-1} \varepsilon_{t-1}) = -E(X_t \varepsilon_{t-1}).$$

- Si (X_t, ε_t) est stationnaire (dans ce cas $E(\Delta X_t \Delta X'_t)$ et $E(\Delta X_t \Delta \varepsilon_t)$ ne dépendent pas de t), on a alors

$$\text{plim} \hat{\beta}_{FD} = \beta_0 - E(\Delta X_t \Delta X'_t)^{-1} E(X_t \varepsilon_{t-1}) \neq \beta_0 \text{ en général.}$$

- N.B. : le biais est indépendant de T .

- ▶ L'estimateur within vérifie quant à lui :

$$\text{plim} \hat{\beta}_W = \beta_0 + \left[\frac{1}{T} \sum_{t=1}^T E(\tilde{X}_t \tilde{X}_t') \right]^{-1} \left[\frac{1}{T} \sum_{t=1}^T E(\tilde{X}_t \varepsilon_t) \right].$$

- ▶ On a par ailleurs :

$$E(\tilde{X}_t \varepsilon_t) = E[(X_t - \bar{X}) \varepsilon_t] = -E[\bar{X} \varepsilon_t].$$

- ▶ Donc, si (X_t, ε_t) est stationnaire,

$$\text{plim} \hat{\beta}_W = \beta_0 - E(\tilde{X}_t \tilde{X}_t')^{-1} E[\bar{X} \bar{\varepsilon}] \neq \beta_0 \text{ en général.}$$

- ▶ Cette fois le biais dépend de T . Par Cauchy-Schwartz,
 $|E[\bar{X} \bar{\varepsilon}]| = |E[(\bar{X} - E(\bar{X})) \bar{\varepsilon}]| \leq (V(\bar{X}) V(\bar{\varepsilon}))^{1/2} = O(1/T).$
- ▶ Dans ce cas, le biais tend vers 0 quand $T \rightarrow \infty$. Mais il peut être grand à distance finie.

- ▶ Principe : par exogénéité faible on a $E(X_s \Delta \varepsilon_t) = 0$ pour $s < t$ donc on peut utiliser les conditions de moments :

$$E[X_s (\Delta Y_t - \Delta X_t' \beta_0)] = 0, \quad \forall s < t. \quad (5)$$

- ▶ Exemple simple : pour $T = 2$ on instrumente, dans l'équation de différences premières, ΔX_2 par X_1 .
- ▶ N.B. : pour le modèle dynamique, il faut au moins observer Y_t sur 3 périodes : on estime l'effet de $Y_2 - Y_1$ sur $Y_3 - Y_2$, en utilisant Y_1 comme instrument de $Y_2 - Y_1$.
- ▶ Pour $T > 2$, on peut utiliser des GMM basés sur (5). Comme précédemment l'estimateur des GMM basé sur l'ensemble des conditions de moment peut être difficile à calculer et n'est pas toujours très fiable à distance finie.
- ▶ En pratique, on utilise souvent certaines conditions de moment seulement, pour se ramener à des 2MC sur les données empilées.

- ▶ Première possibilité : utiliser X_{t-1} comme instrument de ΔX_t .
- ▶ Deuxième possibilité : utiliser ΔX_{t-1} comme instrument de ΔX_t (N.B. : on perd alors une date!).
- ▶ Pour choisir, on peut s'appuyer sur la qualité de la régression de 1ère étape et la variance estimée des 2MC.

Introduction

Exogénéité des résidus mais autocorrélation

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall(t, t')$ (exogénéité stricte)

$E(X_{it}\alpha_i) \neq 0$ mais $E(X_{it}\varepsilon_{it'}) = 0, \forall t' \geq t$ (exogénéité faible)

Exemple : effet de la police sur la criminalité

- ▶ Une augmentation des forces de police permet-elle de réduire la criminalité ?
- ▶ On se focalise ici sur les crimes violents. On considère la régression :

$$\log(\text{crime}_{it}) = \log(\text{police}_{it})\beta_1 + \text{unem}_{it}\beta_2 + \text{incpc}_{it}\beta_3 + \text{black}_{it}\beta_4 + \theta_t + \alpha_i + \varepsilon_{it}.$$

où crime_{it} = nb de crimes violents pour 10^5 hab. dans l'état i à la date t , police_{it} = nb. de policiers pour 10^5 hab., unem_{it} = taux de chômage, incpc_{it} = revenu moyen, black_{it} = proportion de noirs.

- ▶ Problème potentiel : un niveau de criminalité élevé en t peut amener les autorités à augmenter le nombre de policiers après $t \Rightarrow$ corrélation positive entre ε_{it} et police_{it+1} .
- ▶ Modèle estimé sur un sous-échantillon des données de Levitt (1996), PRISON.DTA, utilisé par Wooldridge : 51 états américains entre 1980 et 1993.

```
gen log_police = log(polpc)
```

```
* Command xtset: for panel data, to indicate that state=i, year=t
xtset state year
foreach x of varlist lcriv log_police unem incpc black y81-y93{
    gen d_`x' = d.`x'
}
```

```
* Pooled OLS without clusters
```

```
regress lcriv log_police unem incpc black y81-y93
```

```
* Pooled OLS with clusters
```

```
regress lcriv log_police unem incpc black y81-y93, cluster(state)
```

```
* Within estimator
```

```
* Without the cluster option
```

```
xtreg lcriv log_police unem incpc black y81-y93, fe
```

```
* With the cluster option
```

```
xtreg lcriv log_police unem incpc black y81-y93, fe cluster(state)
```

```
* First difference estimator
```

```
reg d_lcriv d_log_police d_unem d_incpc d_black d_y82-d_y93, cluster(state)
```

Résultats : MCO empilés

Source	SS	df	MS	Number of obs	=	714
Model	173.192926	17	10.1878192	F(17, 696)	=	53.56
Residual	132.384693	696	.190207892	Prob > F	=	0.0000
				R-squared	=	0.5668
				Adj R-squared	=	0.5562
Total	305.577619	713	.428580111	Root MSE	=	.43613

lcriv	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
log_police	1.095963	.101124	10.84	0.000	.8974189	1.294508
unem	7.100307	.9282458	7.65	0.000	5.277809	8.922804
incpc	.0000402	8.68e-06	4.63	0.000	.0000232	.0000573
black	1.716159	.1661151	10.33	0.000	1.390013	2.042306

(Std. Err. adjusted for 51 clusters in state)

lcriv	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
log_police	1.095963	.3639663	3.01	0.004	.3649157	1.827011
unem	7.100307	2.761588	2.57	0.013	1.553494	12.64712
incpc	.0000402	.0000257	1.57	0.124	-.0000114	.0000918
black	1.716159	.6635824	2.59	0.013	.383315	3.049004

- ▶ Différence entre les deux ?
- ▶ Quid du signe des coefficients ? Intérêt des méthodes à effets fixes p/r aux MCO ?

Résultats : estimateur within

Fixed-effects (within) regression
Group variable: **state**

Number of obs = 714
Number of groups = 51

R-sq: within = 0.4676
between = 0.0031
overall = 0.0253

Obs per group: min = 14
avg = 14.0
max = 14

corr(u_i, Xb) = -0.0540

F(17, 646) = 33.38
Prob > F = 0.0000

lcriv	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
log_police	.3695031	.0720416	5.13	0.000	.228039	.5109671
unem	-1.548982	.4138484	-3.74	0.000	-2.361632	-.7363314
incpc	9.75e-07	5.63e-06	0.17	0.863	-.0000101	.000012
black	-.6217821	1.26768	-0.49	0.624	-3.111052	1.867488

Fixed-effects (within) regression
Group variable: **state**

Number of obs = 714
Number of groups = 51

R-sq: within = 0.4676
between = 0.0031
overall = 0.0253

Obs per group: min = 14
avg = 14.0
max = 14

corr(u_i, Xb) = -0.0540

F(17, 50) = 36.23
Prob > F = 0.0000

(Std. Err. adjusted for 51 clusters in state)

lcriv	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
log_police	.3695031	.1567384	2.36	0.022	.0546847	.6843214
unem	-1.548982	.6720916	-2.30	0.025	-2.898918	-.1990462
incpc	9.75e-07	.0000115	0.08	0.933	-.0000222	.0000241
black	-.6217821	1.835126	-0.34	0.736	-4.307742	3.064178

Résultats : différences premières

(Std. Err. adjusted for 51 clusters in state)						
d_lcriv	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
d_log_police	.0542456	.0538304	1.01	0.318	-.0538758	.1623671
d_unem	-.0163343	.3722453	-0.04	0.965	-.7640111	.7313424
d_incp	.0000319	.0000115	2.79	0.007	8.92e-06	.0000549
d_black	-1.743021	2.704599	-0.64	0.522	-7.175368	3.689325

- ▶ Les valeurs estimées sont assez différents du within \Rightarrow exogénéité stricte suspecte.
- ▶ On considère alors la régression :

$$\Delta \log(\text{crime}_{it}) = \Delta \log(\text{police}_{it})\beta_1 + \log(\text{police}_{it})\gamma + \text{controls} + \Delta \varepsilon_{it}.$$

(Std. Err. adjusted for 51 clusters in state)						
d_lcriv	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
d_log_police	.0726276	.0511293	1.42	0.162	-.0300685	.1753238
log_police	-.0255225	.0145134	-1.76	0.085	-.0546736	.0036286
d_unem	.0883762	.3927475	0.23	0.823	-.7004804	.8772328
d_incp	.0000382	.000013	2.93	0.005	.000012	.0000644
d_black	-3.763961	2.337207	-1.61	0.114	-8.45838	.9304588

- ▶ Conclusion ?

Estimation avec exogénéité faible

► Instruments = $\log(\text{police}_{it-1})$ ou $\Delta \log(\text{police}_{it-1})$.

```
by state: gen lag_log_police = log_police[_n-1]
gen d_lag_log_police = d.lag_log_police
```

```
ivreg d_lcriv d_unem d_incpc d_black (d_log_police = lag_log_police), first robust
ivreg d_lcriv d_unem d_incpc d_black (d_log_police = d_lag_log_police), first robust
```

First-stage regressions

Source	SS	df	MS	Number of obs = 663		
Model	.014473114	4	.003618278	F(4, 658) = 1.25		
Residual	1.90863889	658	.002900667	Prob > F = 0.2895		
				R-squared = 0.0075		
				Adj R-squared = 0.0015		
Total	1.923112	662	.002905003	Root MSE = .05386		

d_log_police	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
d_unem	-.233953	.1839071	-1.27	0.204	-.5950686	.1271626
d_incpc	1.21e-06	6.47e-06	0.19	0.852	-.0000115	.0000139
d_black	-3.516948	2.484921	-1.42	0.157	-8.396278	1.362381
lag_log_police	-.0127569	.0097783	-1.30	0.192	-.0319574	.0064436
_cons	.0786864	.0532305	1.48	0.140	-.0258358	.1832086

Instrumental variables (2SLS) regression

Number of obs = 663
 F(4, 658) = 2.89
 Prob > F = 0.0217
 R-squared = .
 Root MSE = .1137

d_lcriv	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
d_log_police	1.476505	1.723324	0.86	0.392	-1.907372	4.860382
d_unem	.2405441	.5399006	0.45	0.656	-.8195917	1.30068
d_incpc	.0000481	.0000154	3.12	0.002	.0000178	.0000783
d_black	1.994339	5.937232	0.34	0.737	-9.663866	13.65254
_cons	-.0351123	.0241679	-1.45	0.147	-.0825678	.0123431

Instrumented: d_log_police
 Instruments: d_unem d_incpc d_black lag_log_police

Estimation avec exogénéité faible

First-stage regressions

Source	SS	df	MS
Model	.02569767	4	.006424418
Residual	1.83956165	607	.003030579
Total	1.86525932	611	.003052798

Number of obs = 612
 F(4, 607) = 2.12
 Prob > F = 0.0769
 R-squared = 0.0138
 Adj R-squared = 0.0073
 Root MSE = .05505

d_log_police	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
d_unem	-.1549976	.1923305	-0.81	0.421	-.5327116 .2227164
d_incp	2.12e-06	6.63e-06	0.32	0.749	-.0000109 .0000152
d_black	-3.365325	2.517615	-1.34	0.182	-8.309618 1.578967
d_lag_log_police	-.1136732	.0466006	-2.44	0.015	-.2051911 -.0221552
_cons	.0094642	.0057333	1.65	0.099	-.0017954 .0207238

Instrumental variables (2SLS) regression

Number of obs = 612
 F(4, 607) = 5.38
 Prob > F = 0.0003
 R-squared = .
 Root MSE = .08771

d_lcriv	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]
d_log_police	-.3505592	.6220623	-0.56	0.573	-1.572215 .8710963
d_unem	-.1251975	.3083298	-0.41	0.685	-.7307201 .4803252
d_incp	.0000485	.000011	4.41	0.000	.0000269 .0000701
d_black	-2.543389	4.749559	-0.54	0.593	-11.87095 6.784174
_cons	-.0162598	.0114898	-1.42	0.158	-.0388243 .0063047

Instrumented: d_log_police
 Instruments: d_unem d_incp d_black d_lag_log_police

- ▶ Estimation de variance des MCO avec *clustering*.
- ▶ Exogénéité stricte.
- ▶ Estimateur des différences premières et estimateur within.
- ▶ Test de l'exogénéité stricte.
- ▶ Exogénéité faible.
- ▶ Estimateur des variables instrumentales sous l'exogénéité faible.