

## Econométrie 2

Chapitre 3 : modèles binaires.

ENSAE 2021-2022

Michael Visser CREST-ENSAE

### Plan



#### Introduction

Modélisation et paramètres d'intérêt

Identification et estimation

Qualité du modèle, sélection des variables

Modèle de probabilité linéaire

Application

### Motivation



- ▶ On cherche à expliquer Y binaire par  $X = (1, X_1, ..., X_{K-1})' \in \mathbb{R}^K$ .
- Les deux valeurs possibles de Y étant arbitraires, on posera toujours  $Y \in \{0,1\}$ .
- Les variables discrètes (et en particulier binaire) sont très largement répandues :
  - En microéconomie : activité vs inactivité, emploi vs chômage, consommation ou non d'un bien durable...
  - En risques de crédit : défaut ou non d'un emprunteur.
  - En assurance : sinistre ou non.
  - En biostatistique : individu guéri vs malade, traitement efficace ou non.
  - En sciences sociales : obtention d'un diplôme ou non, couple vs célibat, vote vs abstention etc.

## Idées générales



- Les modèles linéaires sont mal adaptés pour étudier ce genre de variables...
- ightharpoonup ... Mais on imposera un modèle linéaire sur une variable latente  $Y^*$  liée à Y.
- Comme les modèles correspondants sont non-linéaires en Y, nécessité de bien réfléchir aux paramètres d'intérêt.
- Le fait de ne pas observer  $Y^*$  impliquera la nécessité de normalisation et d'hypothèses paramétriques.
- ▶ Utilisation du maximum de vraisemblance (conditionnel aux X).
- Ces idées se retrouveront dans les chapitres suivants.

## Plan



Introductio

Modélisation et paramètres d'intérêt

Identification et estimation

Qualité du modèle, sélection des variables

Modèle de probabilité linéaire

Application

### Modélisation



Les modèles linéaires sont mal adaptés pour étudier ce genre de variables. En effet, si  $Y \in \{0,1\}$ , on a

$$E(Y|X) = P(Y = 1|X) \in [0, 1].$$
 (1)

Dans un modèle linéaire (sous hypothèse d'exogénéité  $E(\varepsilon|X)=0$ ), on a  $E(Y|X)=X'\beta_0$ . Mais rien n'assure que  $X'\beta_0\in[0,1]$ .

Pour que (1) soit satisfaite, on va supposer que

$$E(Y|X) = F(X'\beta_0), \tag{2}$$

où F(.) est une fonction (connue) strictement croissante bijective de  $\mathbb{R}$  dans ]0, 1[, donc une fonction de répartition (fdr).

▶ N.B. : l'équation (2) est celle d'un modèle linéaire généralisé (GLM en anglais), c'est-à-dire un modèle de la forme :

$$h(E(Y|X)) = X'\beta_0,$$

où h est une fonction connue (dite fonction de lien).



### Modèles non-linéaires et variables latentes



- Le modèle (2) peut s'interpréter en termes de *variables latentes*.
- lacktriangle Supposons qu'il existe une variable continue  $Y^*\in\mathbb{R}$  telle que

$$Y = \mathbb{1}\{Y^* \ge 0\}.$$

ightharpoonup Supposons par ailleurs que  $Y^*$  suive un modèle linéaire :

$$Y^* = X'\beta_0 + \varepsilon, \tag{3}$$

où  $-\varepsilon$  est indépendante de X et a pour fonction de répartition F . Alors

$$P(Y = 1|X) = P(X'\beta_0 + \varepsilon \ge 0|X) = P(-\varepsilon \le X'\beta_0|X) = F(X'\beta_0).$$

- On retrouve donc l'équation (2).
- L'interprétation en termes de variables latentes est, très souvent, naturelle.

## Interprétation en termes de variables latentes



#### Exemple 1 : microéconomie.

- Y = choix binaire de la part d'un agent. Soit  $U_1$  l'utilité (espérée) de l'agent s'il décide Y=1,  $U_0$  son utilité s'il décide Y=0.
- Posons alors  $Y^* = U_1 U_0$  la différence d'utilité entre les deux choix.
- Si l'agent est rationnel, il décide en maximisant son utilité espérée :

$$Y=\mathbb{1}\{U_1\geq U_0\}=\mathbb{1}\{Y^*\geq 0\}.$$

#### **Exemple 2:** finance d'entreprise.

- Le défaut (Y = 1) d'une entreprise survient lorsque la dette de l'entreprise D dépasse un certain seuil S (éventuellement aléatoire).
- ightharpoonup On a alors  $Y^* = D S$ .

## Interprétation en termes de variables latentes



### Exemple 3: biostatistique.

- ightharpoonup Y = 1 si malade, 0 sinon.
- Un individu est guéri lorsque le nombre de bactéries N (par exemple) est descendu en dessous d'un certain seuil S, éventuellement fonction de l'individu.
- ightharpoonup On a alors  $Y^* = N S$ .

#### **Exemple 4**: éducation.

- ightharpoonup Y = 1 si l'individu obtient son diplôme, 0 sinon.
- On obtient son diplôme si notre moyenne M est supérieure à un seuil fixé s.
- ightharpoonup On a alors  $Y^* = M s$ .

# Deux exemples importants : le probit et le logit



- A priori n'importe quel choix est possible pour F.
- Les plus courants sont
  - ightharpoonup F = Φ, fdr d'une  $\mathcal{N}(0,1)$  : modèle probit ;
  - F(x) =  $\Lambda(x) = 1/(1 + \exp(-x))$ , fdr d'une loi *logistique* : modèle logit.
- La différence entre les deux est assez faible. Lorsque  $|x| \to +\infty$ ,  $\varphi(x) = \Phi'(x) \propto e^{-x^2/2}$  et  $\Lambda'(x) = \Lambda(x)(1 \Lambda(x)) = O(e^{-|x|})$ .
- ⇒ queues plus épaisses pour la loi logistique.

# Paramètres et effets marginaux



- ▶ Qualitativement, la j—ème composante  $X_j$  de X aura un effet positif sur P(Y = 1|X) ssi  $\beta_{0j} > 0$ .
- lacktriangle Quantitativement, l'interprétation de  $eta_{0j}$  est plus délicate.
- ▶ Dans le modèle linéaire standard  $E(Y|X) = X'\beta_0$ , le paramètre  $\beta_{0j}$  de  $X_j$  peut s'interpréter comme l'effet marginal de  $X_j$ :

$$\frac{\partial E(Y|X_1=x_1,...,X_{K-1}=x_{K-1})}{\partial x_j}=\beta_{0j}.$$

► Cette valeur est indépendante de  $x = (x_1, ..., x_{K-1})$ .

## Paramètres et effets marginaux



Mais dans les modèles binaires (et non-linéaires plus généralement), l'effet marginal de  $X_i$  n'est plus  $\beta_{0i}$ , et il dépend de x:

$$\frac{\partial E(Y|X=x)}{\partial x_j} = \frac{\partial F(u)}{\partial u}\bigg|_{u=x'\beta_0} \frac{\partial x'\beta_0}{\partial x_j} = f(x'\beta_0)\beta_{0j} \quad \text{avec } f = F'.$$

- Remarque 1 : si f est symétrique unimodale, l'effet d'une variable sur P(Y=1|X) est d'autant plus fort que  $x'\beta_0$  est proche de 0, soit  $P(Y=1|X)\simeq 0.5$ .
- Remarque 2 : on a toujours

$$\frac{\beta_{0I}}{\beta_{0j}} = \frac{\partial E(Y|X=x)/\partial x_I}{\partial E(Y|X=x)/\partial x_j}$$

Donc la comparaison des différents paramètres est licite.

## Paramètres et effets marginaux



• Outre l'estimation de  $\beta_{0j}$ , il est intéressant d'estimer l'effet marginal moyen :

$$\Delta_j = E\left[f(X'\beta_0)\right]\beta_{0j}.$$

C'est l'effet sur Y d'une augmentation marginale de  $X_j$  appliquée à tous les individus.

- On peut également se concentrer sur des sous-populations, en calculant l'effet marginal moyen pour les individus vérifiant  $X \in A$  (par exemple) :  $E\left[f(X'\beta_0)|X\in A\right]\beta_{0j}$  ou encore l'effet marginal à la moyenne,  $f\left(E(X)'\beta_0\right)\beta_{0j}$ .
- Pour les variables explicatives discrètes (dichotomiques), l'effet marginal est remplacé par

$$F(x'_{-j}\beta_{0-j}+\beta_{0j})-F(x'_{-j}\beta_{0-j}).$$

où  $x_{-j}=(1,x_1,...,x_{j-1},x_{j+1},...,x_{K-1})'$ . L'effet moyen d'un changement universel de  $X_i$  de 0 à 1 est alors :

$$E\left[F(X'_{-i}\beta_{0-j}+\beta_{0j})-F(X'_{-i}\beta_{0-j})\right].$$



# Une spécificité du modèle logit : les odds-ratios.





- On définit le risque (ou odd) comme égal à P(Y = 1|X)/P(Y = 0|X).
- Dans le cas du logit :

$$\frac{P(Y=1|X=x)}{P(Y=0|X=x)} = \frac{1/(1+e^{-x'\beta_0})}{e^{-x'\beta_0}/(1+e^{-x'\beta_0})} = e^{x'\beta_0}$$

ightharpoonup Considérons une variable explicative  $X_i \in \{0,1\}$ . On a alors :

$$e^{\beta_{0j}} = \frac{P(Y=1|X_{-j}=x_{-j},X_j=1)/P(Y=0|X_{-j}=x_{-j},X_j=1)}{P(Y=1|X_{-j}=x_{-j},X_j=0)/P(Y=0|X_{-j}=x_{-j},X_j=0)}.$$

lacktriangle Donc  $e^{eta_{f 0}}$  est égal au rapport des risques (odds-ratio) correspondant à  $X_i = 1$  et  $X_i = 0$ . Il est indépendant de la valeur de  $X_{-i}$ .

## Plan



Introductio

Modélisation et paramètres d'intérê

Identification et estimation

Qualité du modèle, sélection des variables

Modèle de probabilité linéaire

Application

### Identification



Revenons à l'équation :

$$Y = \mathbb{1}\{X'\beta_0 + \varepsilon \ge 0\}.$$

- Deux questions : (i) pourquoi fixer le seuil à 0? (ii) pourquoi fixer la variance de  $\varepsilon$  (à 1 pour le probit, à  $\pi^2/3$  pour le logit)?
- Raison : le modèle n'est pas identifiable sinon. En effet, on a :

$$Y=\mathbb{1}\{\beta_{01}+X_{-1}'\beta_{0-1}+\varepsilon\geq s\}\Longleftrightarrow Y=\mathbb{1}\{\beta_{01}-s+X_{-1}'\beta_{0-1}+\varepsilon\geq 0\}.$$

- ▶ En d'autres termes, on ne peut pas identifier séparément la constante  $\beta_{01}$  et le seuil s. On fixe donc (arbitrairement) s à 0.
- De même, on ne peut pas identifier de façon jointe  $\beta_0$  et la variance  $\sigma_0^2$  du résidu  $\varepsilon$ . En effet,

$$Y = \mathbb{1}\{X'\beta_0 + \varepsilon \ge 0\} \iff Y = \mathbb{1}\{X'(\beta_0/\sigma_0) + \varepsilon/\sigma_0 \ge 0\}.$$

ightharpoonup On fixe donc arbitrairement  $\sigma_0$ .



### Identification



### Proposition 1

Si s et  $\sigma_0$  sont fixés et E(XX') est inversible, le modèle est identifié.

**Preuve**: soit  $P_{\beta}$  la loi des observations lorsque le vrai paramètre est  $\beta$ . Il s'agit de montrer que la fonction  $\beta \mapsto P_{\beta}$  est injective. Dans notre modèle conditionnel, on peut montrer que l'identification est équivalente à

$$P_{\beta}(Y=1|X) = P_{\beta'}(Y=1|X) \Rightarrow \beta = \beta' \quad \forall (\beta, \beta').$$

Or

$$(E(XX') \text{ est inversible }) \iff (X'\lambda = 0 \Longrightarrow \lambda = 0)$$

Par conséquent,

$$P_{\beta}(Y = 1|X) = P_{\beta'}(Y = 1|X) \iff F(X'\beta) = F(X'\beta')$$
  
 $\iff X'\beta = X'\beta'$   
 $\iff \beta = \beta' \sqcap$ 

# Estimation du modèle : le maximum de vraisemblance



- On s'intéresse maintenant à l'estimation de  $\beta_0$  à partir d'un échantillon i.i.d.  $((Y_1, X_1), ..., (Y_n, X_n))$ .
- ► Comme le modèle est paramétrique, on peut l'estimer par maximum de vraisemblance.
- ► La densité de Y conditionnellement à X s'écrit :

$$P(Y = y | X = x) = [P(Y = 1 | X = x)]^{y} [P(Y = 0 | X = x)]^{1-y}$$
  
=  $F(x'\beta)^{y} (1 - F(x'\beta))^{1-y}$ .

La fonction de vraisemblance d'un échantillon i.i.d.  $(Y,X) = ((Y_1,X_1),...,(Y_n,X_n))$  conditionnellement à X s'écrit alors

$$\mathcal{L}_n(Y|X;\beta) = \prod_{i=1}^n F(X_i'\beta)^{Y_i} (1 - F(X_i'\beta))^{1-Y_i}.$$

# Estimation du modèle : le maximum de vraisemblance



▶ Un estimateur du maximum de vraisemblance est alors défini par :

$$\widehat{\beta} \in \arg\max_{\beta \in \mathbb{R}^K} \mathcal{L}_n(Y|X;\beta).$$

- Remarquez que cet estimateur n'est pas forcément unique, et il peut ne pas exister.
- Remarquez aussi que  $\mathcal{L}_n(Y|X;\beta)$  est la vraisemblance conditionnelle à X. En notant  $g(X_i)$  la densité de  $X_i$ , la vraisemblance non-conditionnelle s'écrit

$$\mathcal{L}_n(Y,X;\beta) = \prod_{i=1}^n F(X_i'\beta)^{Y_i} (1 - F(X_i'\beta))^{1-Y_i} g(X_i).$$

Comme dans la pratique on ne s'intéresse pas à la distribution de X, on se focalise sur la vraisemblance conditionnelle.

## Conditions du premier ordre du programme





On maximise plutôt la log-vraisemblance :

$$\ell_n(Y|X;\beta) = \sum_{i=1}^n Y_i \ln (F(X_i'\beta)) + (1-Y_i) \ln (1-F(X_i'\beta))$$

▶ On a  $\partial F(X_i'\beta)/\partial \beta = f(X_i'\beta)X_i$ . Donc :

$$\frac{\partial \ell_n}{\partial \beta}(Y|X;\beta) = \sum_{i=1}^n \left[ Y_i \frac{f(X_i'\beta)}{F(X_i'\beta)} + (1 - Y_i) \frac{-f(X_i'\beta)}{1 - F(X_i'\beta)} \right] X_i$$

Soit encore

$$\frac{\partial \ell_n}{\partial \beta}(Y|X;\beta) = \sum_{i=1}^n \frac{f(X_i'\beta)}{F(X_i'\beta)(1 - F(X_i'\beta))} [Y_i - F(X_i'\beta)] X_i. \tag{4}$$

Les conditions du premier ordre s'écrivent donc :

$$\sum_{i=1}^{n} \frac{f(X_{i}'\widehat{\beta})}{F(X_{i}'\widehat{\beta})(1 - F(X_{i}'\widehat{\beta}))} \left[ Y_{i} - F(X_{i}'\widehat{\beta}) \right] X_{i} = 0$$

qui n'admet pas de solution analytique simple en général.



(5)

### Existence et unicité de solution



- Si une variable dichotomique  $X_j$  est telle que : si  $x_{ij}=1 \Rightarrow y_i=1$  pour tout i (ou  $x_{ij}=1 \Rightarrow y_i=0$  pour tout i), l'estimateur n'existe pas.
- ► En effet,  $\partial \ell_n/\partial \beta_j$  s'écrit alors (on considère le cas  $x_{ij}=1 \Rightarrow y_i=1$  pour tout i)

$$\sum_{i=1}^{n} \frac{f(x_{i}'\beta)}{F(x_{i}'\beta)(1 - F(x_{i}'\beta))} [y_{i} - F(x_{i}'\beta)] x_{ij} = \sum_{i:x_{ij}=1} \frac{f(x_{i}'\beta)}{F(x_{i}'\beta)} > 0 \quad \forall \beta$$

L'exemple montre que, parmi les observations telles que  $x_{ij}=1$ , la variable  $y_i$  doit varier à travers i pour pouvoir estimer  $\beta_{0j}$ . En absence de variation, des logiciels comme Stata indiquent que le paramètre  $\beta_{0j}$  n'est pas identifiable et "expulse" automatiquement la variable  $x_i$  du modèle.

### Existence et unicité de solution



▶ Dans le cas du modèle logit, on a  $\Lambda' = \Lambda(1 - \Lambda)$ , donc

$$\frac{\partial^2 \ell_n}{\partial \beta \partial \beta'} (Y|X;\beta) = -\sum_{i=1}^n \Lambda'(X_i'\beta) X_i X_i' << 0.$$

La matrice des dérivés secondes est définie négative. La log-vraisemblance est donc strictement concave  $\Rightarrow$  les conditions de premier ordre ont au plus une solution, et cette solution correspond au maximum global.

- Dans le cas du modèle probit, on peut également montrer que la log-vraisemblance est bien strictement concave.
- ▶ Dans le cas général, le programme n'est pas nécessairement concave et il peut y avoir plusieurs solutions. Il faut alors (dans l'idéal) vérifier que la solution corresponde bien à un maximum global.

## Remarques sur l'optimisation



- Contrairement à l'estimateur des MCO, l'estimateur du maximum de vraisemblance ne peut pas, en général, s'exprimer d'une manière explicte.
- L'estimateur peut être obtenu numériquement par un algorithme de Newton-Raphson (il existe d'autres algorithmes). Partant de  $\beta^{(0)}$  quelconque, on définit la suite  $\left(\beta^{(m)}\right)_{m\in\mathbb{N}}$  par :

$$\beta^{(m+1)} = \beta^{(m)} - \left[ \frac{\partial^2 \ell_n}{\partial \beta \partial \beta'} (Y|X; \beta^{(m)}) \right]^{-1} \frac{\partial \ell_n}{\partial \beta} (Y|X; \beta^{(m)})$$

- Par concavité stricte de  $\ell_n(Y|X;\beta)$ , la suite  $\beta^{(m)}$ , si elle converge, tend nécessairement vers l'EMV.
- ▶ Dans le cas d'un modèle logit ou probit les itérations convergent typiquement vite et rapidement.

# Propriétés asymptotiques



### Proposition 2

Sous plusieurs conditions techniques (voir cours de Statistique 1), on a  $\widehat{\beta} \stackrel{P}{\longrightarrow} \beta_0$  et

$$\sqrt{n}(\widehat{\beta} - \beta_0) \stackrel{d}{\longrightarrow} \mathcal{N}(0, \mathcal{I}_1^{-1}(\beta_0)),$$

où  $\mathcal{I}_1(eta_0)$  est l'information de Fisher associée à une observation. De plus,

$$\mathcal{I}_1(\beta_0) = E\left(\frac{f^2(X'\beta_0)}{F(X'\beta_0)(1 - F(X'\beta_0))}XX'\right).$$

On peut l'estimer de façon convergente par :

$$\widehat{\mathcal{I}_1(\beta_0)} = \frac{1}{n} \sum_{i=1}^n \frac{f^2(X_i'\widehat{\beta})}{F(X_i'\widehat{\beta})(1 - F(X_i'\widehat{\beta}))} X_i X_i'.$$

Rappel : l'EMV est asymptotiquement le meilleur estimateur "régulier" : si un autre estimateur  $\widetilde{\beta}$  vérifie  $\sqrt{n}\left(\widetilde{\beta}-\beta_0\right) \stackrel{d}{\longrightarrow} \mathcal{N}(0,V)$ , alors

## Propriétés asymptotiques



**Preuve de la formule sur**  $\mathcal{I}_1(\beta_0)$  : on a

$$\mathcal{I}_1(eta_0) = V\left(rac{\partial \ell_1}{\partial eta}(Y|X;eta_0)
ight)$$

où  $\ell_1(Y|X;\beta_0)$  est la log-vraisemblance (évaluée en  $\beta_0$ ) d'une observation :

$$\ell_1(Y|X; \beta_0) = Y \ln(F(X'\beta_0)) + (1 - Y) \ln(1 - F(X'\beta_0))$$

Par décomposition de la variance :

$$\mathcal{I}_{1}(\beta_{0}) = E\left[V\left(\frac{\partial \ell_{1}}{\partial \beta}(Y|X;\beta_{0})\middle|X\right)\right] + V\left[E\left(\frac{\partial \ell_{1}}{\partial \beta}(Y|X;\beta_{0})\middle|X\right)\right].$$

Or (cf. équation (4))

$$\frac{\partial \ell_1}{\partial \beta}(Y|X;\beta_0) = \frac{f(X'\beta_0)}{F(X'\beta_0)(1 - F(X'\beta_0))} [Y - F(X'\beta_0)] X.$$



# Propriétés asymptotiques



Donc

$$E\left(\frac{\partial \ell_1}{\partial \beta}(Y|X;\beta_0)\middle|X\right)=0$$

car  $E(Y - F(X'\beta_0)|X) = 0$ , et

$$V\left(\frac{\partial \ell_{1}}{\partial \beta}(Y|X;\beta_{0})\middle|X\right) = E\left[\left(\frac{\partial \ell_{1}}{\partial \beta}(Y|X;\beta_{0})\right)\left(\frac{\partial \ell_{1}}{\partial \beta}(Y|X;\beta_{0})\right)'\middle|X\right]$$

$$= E\left[\frac{f(X'\beta_{0})^{2}}{F(X'\beta_{0})^{2}(1-F(X'\beta_{0}))^{2}}\left[Y-F(X'\beta_{0})\right]^{2}XX'\middle|X\right]$$

$$= \frac{f^{2}(X'\beta_{0})XX'}{F(X'\beta_{0})(1-F(X'\beta_{0}))}$$

car  $E\left[(Y-F(X'eta_0))^2\Big|X\right]=F(X'eta_0)(1-F(X'eta_0))$ . D'où le résultat.

## Tests d'hypothèses.



On souhaite tester une hypothèse du type

$$H_0: R\beta_0 = 0$$
 contre  $H_1: R\beta_0 \neq 0$  ( $R$  matrice  $p \times K, p \leq K$ ).

- ▶ Par exemple,  $\beta_{0j} = 0$  ou  $\beta_{02} = ... = \beta_{0K-1} = 0$  (c'est à dire  $\beta_{0-1} = 0$ ).
- On utilise l'un des trois tests liés au maximum de vraisemblance : le test de Wald, le test du score ou le test de rapport de vraisemblance. Les statistiques de test correspondantes s'écrivent :

$$\xi_{n}^{W} = n\widehat{\beta}'R'\left[R\widehat{I_{1}(\beta_{0})}^{-1}R'\right]^{-1}R\widehat{\beta}$$

$$\xi_{n}^{S} = \frac{1}{n}\frac{\partial\ell_{n}}{\partial\beta'}(Y|X;\widehat{\beta}_{C})\widehat{I_{1}(\beta_{0})}^{-1}\frac{\partial\ell_{n}}{\partial\beta}(Y|X;\widehat{\beta}_{C})$$

$$\xi_{n}^{R} = 2\left[\ell_{n}(Y|X;\widehat{\beta}) - \ell_{n}(Y|X;\widehat{\beta}_{C})\right]$$

où  $\widehat{\beta}_C$  est l'estimateur du maximum de vraisemblance contraint, i.e. estimé sous  $H_0$ .

## Tests d'hypothèses.



- Concernant la statistique  $\xi_n^W$ ,  $\widehat{\mathcal{I}_1(\beta_0)}$  correspond à la formule de la page 24.
- Concernant la statistique  $\xi_n^S$ , il s'agit de cette même formule sauf que  $\widehat{\beta}$  est remplacé par  $\widehat{\beta}_C$ .
- Remarquez que les trois statistiques ont tendance à être "petites" sous l'hypothèse H<sub>0</sub>.
- Sous  $H_0$ ,  $\xi_n^T \stackrel{d}{\longrightarrow} \chi^2(p)$  (T = W, S ou R).
- La région critique d'un test de niveau asymptotique  $\alpha$  est donc de la forme  $\{\xi_n^T > q_p^{Chi-2}(1-\alpha)\}$  où  $q_p^{Chi-2}(y)$  est le quantile d'ordre y d'un  $\chi^2(p)$ .
- Lorsqu'on teste  $H_0: \beta_{0j} = 0$  contre  $H_1: \beta_{0j} \neq 0$ , le t-test habituel est le plus souvent utilisé. Ce test donne le même résultat que le test de Wald, car (à vérifier)  $\xi_n^W = \left(\widehat{\beta}_j/se(\widehat{\beta}_j)\right)^2 \equiv t_j^2$  et  $|t_j| > q^N(1-\alpha/2) \Leftrightarrow \xi_n^W > q_p^{Chi-2}(1-\alpha)$  où  $q^N(1-\alpha/2)$  est le quantile d'ordre  $1-\alpha/2$  d'une  $\mathcal{N}(0,1)$ .



## Plan



Introductio

Modélisation et paramètres d'intérêt

Identification et estimation

Qualité du modèle, sélection des variables

Modèle de probabilité linéaire

Application

# Pouvoir explicatif du modèle



▶ On définit, de façon similaire au  $R^2$ , le pseudo- $R^2$  par :

pseudo-
$$R^2 = 1 - \frac{\ell_n(Y|X; \widehat{\beta})}{\ell_n(Y|X; \widehat{\beta}_C)}$$

où  $\widehat{\beta}_C$  est le paramètre estimé sous l'hypothèse nulle  $\beta_{0-1}=0$ .

▶ Puisque  $0 > \ell_n(Y|X; \widehat{\beta}) \ge \ell_n(Y|X; \widehat{\beta}_C)$ , le pseudo- $R^2$  appartient à ]0,1]. Il est proche de 1 lorsque

$$Y_i = 1$$
 et  $F(X_i'\widehat{\beta}) \simeq 1$  ou  $Y_i = 0$  et  $F(X_i'\widehat{\beta}) \simeq 0$ .

- Comme le  $R^2$ , le pseudo- $R^2$  augmente mécaniquement avec le nombre de variables.
- Autres indicateurs : table de concordance, score, pourcentage de paires concordantes...

### Choix des variables



- ► Arbitrage entre :
  - l'accroissement du pouvoir explicatif du modèle;
  - la perte de précision liée à l'estimation de nombreux paramètres.
- on peut faire des tests de nullité des variables, éventuellement via des procédures séquentielles (forward, backward, ...).
- Inconvénient : lorsque n tend vers l'infini, on est conduit à accepter la plupart des variables explicatives.
- on peut utiliser les critères d'information AIC (Akaike Information Criterion, Akaike, 1973) ou BIC (Bayesian Information Criterion, Schwarz, 1978).
- Ces critères sont utilisés pour résoudre le problème du choix de modèles. Supposons que l'on ait J modèles paramétriques possibles :

$$\{(P_{\beta^{(1)}})_{\beta^{(1)} \in B^{(1)}}, ..., (P_{\beta^{(J)}})_{\beta^{(J)} \in B^{(J)}}\}$$
.

On souhaite sélectionner le vrai modèle.



### Choix des variables



Critère d'Akaike pour le modèle j ayant pi paramètres :

$$AIC(j) = \ell_n(Y|X; \widehat{\beta}^{(j)}) - p_j$$

On choisit alors le modèle  $j_0 = \arg\max_j AIC(j)$ .

- Ce critère ne conduit pas au bon choix lorsque n tend vers l'infini. En effet, le critère ne pénalise pas assez le nombre de paramètres.
- Pour corriger cela, Schwarz (1978) propose le critère suivant :

$$\mathsf{BIC}(j) = \ell_n(\mathsf{Y}|\mathsf{X};\widehat{\beta}^{(j)}) - \frac{p_j}{2} \ln(n)$$

## Plan



Introduction

Modélisation et paramètres d'intérê

Identification et estimation

Qualité du modèle, sélection des variables

Modèle de probabilité linéaire

Application

### Intérêt du modèle linéaire



Parfois, pour des raisons de simplicité, on estime un modèle de probabilité linéaire plutôt qu'un modèle logit ou probit :

$$E(Y|X) = X'\beta_0.$$

► Exemple : données de panel. Supposons que

$$E(Y_{it}|X_{it},\alpha_i)=X'_{it}\beta_0+\alpha_i,$$

où  $\alpha_i$  est un effet individuel a priori corrélé aux  $X_{it}$ .

On peut éliminer l'effet inobservé par différence ou par within :

$$E(Y_{it} - Y_{it-1}|X_{it}, X_{it-1}) = (X_{it} - X_{it-1})'\beta_0.$$

Dans les modèles non-linéaires, ce n'est pas aussi simple car

$$E(Y_{it} - Y_{it-1}|X_{it}, X_{it-1}, \alpha_i) = F(X'_{it}\beta + \alpha_i) - F(X'_{it-1}\beta + \alpha_i).$$

Par ailleurs, l'estimation par maximum de vraisemblance de  $(\beta, \alpha_1, ..., \alpha_n)$  n'est pas convergente à cause du problème des paramètres incidents : le nombre de paramètres tend vers l'infini avec n.

## Modélisation et estimation



Le modèle de probabilité linéaire peut se réécrire  $Y = X'\beta_0 + \varepsilon$ , avec

$$\varepsilon = \left| \begin{array}{cc} 1 - X'\beta_0 & \text{avec la probabilit\'e (conditionnelle)} & X'\beta_0 \\ - X'\beta_0 & \text{avec une probabilit\'e} & 1 - X'\beta_0 \end{array} \right|$$

On a donc :

$$V(\varepsilon|X) = E(\varepsilon^{2}|X) = X'\beta_{0}(1 - X'\beta_{0})^{2} + (1 - X'\beta_{0})(X'\beta_{0})^{2}$$
  
=  $X'\beta_{0}(1 - X'\beta_{0}).$ 

- Le modèle est hétéroscédastique. On peut l'estimer par MCO mais aussi par MCQG :
  - ▶ On estime  $\beta_0$  par MCO :  $\widehat{\beta}_{MCO}$ .
  - ightharpoonup On réestime  $eta_0$  par

$$\widehat{\beta}_{MCGQ} = \arg\min_{\beta} \sum_{i=1}^{n} \frac{1}{X_{i}' \widehat{\beta}_{MCO} (1 - X_{i}' \widehat{\beta}_{MCO})} \left[ Y_{i} - X_{i}' \beta \right]^{2}$$

L'estimateur des MCQG est plus précis en théorie mais pas forcément en pratique, si  $X_i'\widehat{\beta}_{MCO} \simeq 0$  ou  $\simeq 1$  pour certains i.



# Comparaison logit/probit/modèle linéaire



- La différence avec les modèles logit, probit et linéaire est que l'on ne choisit pas le même F(.) dans  $E(Y|X) = F(X'\beta_0) : F = \Lambda, \Phi$ , ou Identité suivant le modèle considéré.
- Il existe des modèles semi-paramétriques où l'on suppose que  $P(Y=1|X)=F(X'\beta_0)$  avec F et  $\beta_0$  inconnus. Équivaut à considérer le modèle latent  $Y^*=X'\beta_0+\varepsilon$  avec  $\varepsilon\perp\!\!\!\perp X$  de loi inconnue.
- Ces modèles sont moins restrictifs mais plus difficiles à estimer.
- Par ailleurs, les résultats des logit, probit et modèles linéaires sont souvent très proches en termes d'effets marginaux.
- ► En termes de coefficients, on aura en général

$$\widehat{eta}_{
m logit} \simeq 1.6 \widehat{eta}_{
m probit} \simeq 4 \widehat{eta}_{
m linéaire}.$$

#### Plan



Introduction

Modélisation et paramètres d'intérêt

Identification et estimation

Qualité du modèle, sélection des variables

Modèle de probabilité linéaire

**Application** 

#### Exemple : activité des femmes.



- ▶ On cherche à expliquer l'activité (Y = 1, Y = 0 sinon) des femmes suivant leur âge, leur diplôme et leur situation familiale (en couple ou non, nombre d'enfants de moins de 3 ans).
- On utilise les données de l'enquête emploi française 2012. On se concentre sur les femmes de moins de 65 ans ayant terminé leurs études.
- Modalités de la variable de diplôme DDIPL :
  - 1 Diplôme supérieur
  - 3 Baccalauréat + 2 ans
  - 4 Baccalauréat ou brevet professionnel ou autre diplôme de ce niveau
  - 5 CAP, BEP ou autre diplôme de ce niveau
  - 6 Brevet des collèges
  - 7 Aucun diplôme ou CEP

#### Code Stata



```
destring age ddipl, replace
* Sélection de l'échantillon : femme en lère interrogation, ayant fini leur
* études et de moins de 65 ans
keep if rqi=="1" & sexe=="2" & fordat!="" & acteu!="" & age<=65
gen en_couple = (TYPMEN5=="3" | TYPMEN5=="4")
gen actif = (acteu!="3")
logit actif c.age c.age#c.age NBENF3 en couple i.ddipl
* Calcul des effets marginaux
margins, dydx(_all)
margins, dydx(_all) atmeans
* Calcul des odds ratios
logistic actif c.age c.age #c.age NBENF3 en couple i.ddipl
* Comparaison des effets marginaux avec le probit
probit actif c.age c.age#c.age NBENF3 en couple i.ddipl
margins, dydx( all)
```

# Résultats : coefficients du logit



```
Iteration 0: log likelihood = -17112.651
Iteration 1: log likelihood = -13273.506
Iteration 2: log likelihood = -13110.555
Iteration 3: log likelihood = -13110.084
Iteration 4: log likelihood = -13110.084
```

Logistic regression

Log likelihood = -13110.084

actif	Coef.	Std. Err.	z	P>   z	[95% Conf.	<pre>Interval]</pre>
age	.3588415	.008609	41.68	0.000	.3419681	.3757148
c.age#c.age	004898	.0000999	-49.03	0.000	0050938	0047022
NBENF3 en_couple	-1.433909 2182632	.0459917	-31.18 -6.29	0.000	-1.524051 2862983	-1.343766 1502281
ddipl 3 4 5 6 7	1536238 4915752 6802183 890034 -1.411182	.0649168 .0593656 .0566461 .0680838	-2.37 -8.28 -12.01 -13.07 -25.21	0.018 0.000 0.000 0.000 0.000	2808584 6079296 7912426 -1.023476 -1.520886	0263893 3752208 569194 7565922 -1.301478
_cons	-3.342729	.180223	-18.55	0.000	-3.69596	-2.989499

# Résultats : effets marginaux moyens



Average marginal effects Number of obs = 29,248

Model VCE : OIM

 $\begin{array}{lll} {\tt Expression} & : & {\tt Pr(actif), predict()} \\ {\tt dy/dx w.r.t.} & : & {\tt age NBENF3 en\_couple 3.ddipl 4.ddipl 5.ddipl 6.ddipl 7.ddipl} \end{array}$ 

	dy/dx	Delta-method Std. Err.	z	P>   z	[95% Conf.	Interval]
age NBENE3	0129698 2050776	.0001931	-67.18 -32.77	0.000	0133482 217342	0125913 1928131
en_couple	031216	.0049551	-6.30	0.000	0409278	0215042
ddipl						
3	0185428	.0078345	-2.37	0.018	0338981	0031874
4	0637538	.0075632	-8.43	0.000	0785773	0489302
5	0916208	.0073535	-12.46	0.000	1060334	0772083
6	1247672	.0097925	-12.74	0.000	1439602	1055741
7	2160232	.0080491	-26.84	0.000	2317991	2002474

Note: dy/dx for factor levels is the discrete change from the base level.

# Résultats : effets marginaux à la moyenne



```
Conditional marginal effects
                                                   Number of obs
                                                                            29,248
Model VCE
              : OTM
              : Pr(actif), predict()
Expression
dv/dx w.r.t. : age NBENF3 en couple 3.ddipl 4.ddipl 5.ddipl 6.ddipl 7.ddipl
                                      43.60835 (mean)
at.
              : age
                NBENE3
                                      .1043832 (mean)
                en couple
                                      .7026805 (mean)
                                      .1625068 (mean)
                1.ddipl
                3.ddipl
                                      .1498222 (mean)
                4.ddipl
                                      .1864401 (mean)
                                      .218032 (mean)
                5.ddipl
                6.ddipl
                                      .0816124 (mean)
                7.ddipl
                                      .2015864 (mean)
                            Delta-method
                     dv/dx
                                                   P> | z |
                                                              [95% Conf. Interval]
                              Std. Err.
          age
                 -.0068105
                              .0001604
                                         -42.46
                                                   0.000
                                                            -.0071248
                                                                         -.0064961
      NBENF3
                 -.1428768
                              .0049677
                                         -28.76
                                                   0.000
                                                            -.1526133
                                                                         -.1331404
   en couple
                 -.0217481
                              .0034523
                                          -6.30
                                                   0.000
                                                            -.0285144
                                                                         -.0149817
       ddipl
                 -.0097966
                              .0041521
                                          -2.36
                                                   0.018
                                                            -.0179346
                                                                         -.0016587
           4
                  -.036382
                              .0043838
                                         -8.30
                                                   0.000
                                                            -.0449742
                                                                         -.0277898
                                         -12.28
                                                   0.000
                  -.054696
                              .0044551
                                                            -.0634279
                                                                         -.0459642
```

Note: dy/dx for factor levels is the discrete change from the base level.

-11.54

-24.47

0.000

0.000

-.0917188

-.1667551

.0067935

.006309

-.0784038

-.1543896

7

-.0650888

-.1420242

# Résultats : rapports des risques (odds-ratios)



0.2339

.6871375

.5659815

.4692629

.2721292

.0503127

Logistic regression Number of obs = 29,248 ER LR chi2(9) = 8005.14 ER Prob > chi2 = 0.0000

Pseudo R2

0.000

0.000

0.000

0.000

0.000

.544477

.4532812

.3593438

.2185182

.0248236

Log likelihood = -13110.084

4

5

6

7

\_cons

.6116621

.5065064

.4106418

.2438549

.0353404

actif	Odds Ratio	Std. Err.	z	P>   z	[95% Conf.	Interval]
age	1.43167	.0123253	41.68	0.000	1.407715	1.456032
c.age#c.age	.9951139	.0000994	-49.03	0.000	.9949191	.9953088
NBENF3 en_couple	.2383754 .8039138	.0109633	-31.18 -6.29	0.000	.2178277 .7510386	.2608613 .8605116
ddipl 3	.8575946	.0556723	-2.37	0.018	.7551353	.9739559

-8.28

-12.01

-13.07

-25.21

-18.55

.0363117

.0286916

.0279581

.0136491

.0063691

#### Résultats : sortie du probit



```
Iteration 0: log likelihood = -17112.651
Iteration 1: log likelihood = -13167.282
Iteration 2: log likelihood = -13144.263
Iteration 4: log likelihood = -13144.235
```

Probit regression

Log likelihood = -13144.235

Number of obs = 29,248 LR chi2(9) = 7936.83 Prob > chi2 = 0.0000 Pseudo R2 = 0.2319

actif	Coef.	Std. Err.	z	P>   z	[95% Conf.	Interval]
age	.208209	.0049031	42.46	0.000	.1985991	.2178189
c.age#c.age	0028442	.0000567	-50.19	0.000	0029553	0027331
NBENF3 en_couple	810221 1252294	.0265808	-30.48 -6.37	0.000	8623183 1637702	7581237 0866885
ddipl 3 4 5 6 7	0674434 2627095 3680032 4981455 8048283	.035364 .0324658 .0311346 .0381265 .0309099	-1.91 -8.09 -11.82 -13.07 -26.04	0.057 0.000 0.000 0.000 0.000	1367555 3263413 429026 5728721 8654106	.0018688199077830698044234189744246
_cons	-1.957251	.1033402	-18.94	0.000	-2.159794	-1.754708

### Résultats : effets marginaux du probit



Average marginal effects Number of obs = 29,248

Model VCE : OIM

Expression : Pr(actif), predict()

dy/dx w.r.t. : age NBENF3 en\_couple 3.ddipl 4.ddipl 5.ddipl 6.ddipl 7.ddipl

	dy/dx	Delta-method Std. Err.	l z	P>   z	[95% Conf.	Interval]
age NBENF3 en_couple	0128503 2043994 0315924	.0001954 .0064625 .0049528	-65.76 -31.63 -6.38	0.000 0.000 0.000	0132333 2170657 0412996	0124673 1917331 0218851
ddip1 3 4 5 6 7	0146067 0609368 0883387 124402 217612	.0076632 .0074383 .0072784 .0098168	-1.91 -8.19 -12.14 -12.67 -27.23	0.057 0.000 0.000 0.000 0.000	0296264 0755155 1026041 1436425 2332756	.000413 046358 0740732 1051614 2019484

Note: dy/dx for factor levels is the discrete change from the base level.

# Questions sur l'application



Accepte-t-on l'hypothèse nulle du modèle sans explicative?

Réponse : On rejette  $H_0$  :  $\beta_{0-1}=0$  en utilisant le test de rapport de vraisemblance. Pour le modèle Logit (page 40), la valeur de la statistique  $\xi_n^R$  vaut 8005, le p-value vaut 0.000, on rejette fortement  $H_0$ . Idem pour le modèle Probit.

► Quelles sont les variables significatives à 5%?

Réponse : Toutes les variables sont significatives à 5 % dans le cas du modèle Logit. Dans le cas du Probit seule la variable indiquant que DDIPL=3 ne l'est pas.

Quelles sont les formules utilisées pour calculer les effet marginaux moyens et à la moyenne de la variable âge?

Réponse : On calcule l'effet marginal moyen de la variable âge via la formule

$$\frac{1}{n}\sum_{i=1}^{n}f(x_{i}'\widehat{\beta})\left(\widehat{\beta}_{age}+2\widehat{\beta}_{agecarre} \ age_{i}\right).$$

Pour calculer l'effet marginal à la moyenne, on utilise la même formule sauf que les variables  $x_i$  et  $age_i$  sont remplacées par la moyenne de ces variables dans l'échantillon.

### Questions sur l'application



Estime-t-on ici l'effet causal des variables?

Réponse : On estime l'effet causal des variables si le modèle est bien spécifié et si  $\epsilon$  et X sont bien indépendantes.

Comment calcule-t-on le rapport des risques (odds-ratio) correspondant à une variable continue?

Réponse : Comme dans le cas d'une variable explicative binaire (voir page 14). Par exemple, pour la variable âge, le odds-ratio dans le tableau à la page 45 correspond à  $e^{\widehat{\beta}_{age}}$  où  $\widehat{\beta}_{age}$  est l'estimation du paramètre associé à l'âge.

Les résultats des deux modèles sont-ils comparables?

Réponse : Oui, toutes les variables sont significatives dans les deux modèles (sauf celle correspondant à DDIPL==3), et les coefficients estimés ont le même signe. Les effets marginaux sont par ailleurs très proches.

#### L'essentiel



- Modélisation via les variables latentes. Modèles logit, probit.
- ► Effets marginaux : dérivation, interprétation.
- Odds-ratios pour le logit.
- Identification (normalisation), estimation via le max. de vrais.
- Choix de modèle via les critères d'information.
- Modèle de probabilité linéaire : intérêt, limites.